南昌大学
NANCHANG UNIVERSITY

大数据优化：理论、算法及其应用

主讲人：彭振华

数学与计算机学院

2026年

约束优化理论

第 五 部分

对偶理论

凸优化问题的最优性理论

一般约束优化问题的最优性理论

$$\min_x \ f(x)$$

无约束优化理论回顾

- (一阶必要条件) 假设 f 在全空间R^n可微. 如果x^*是一个局部极小点, 那么 $\nabla f(x^*) = 0$. (若函数 f 是凸的，则 $\nabla f(x^*) = 0 \rightarrow x^*$是 f 的全局极小点)
- (一阶充要条件) 假设 f 是适当且凸的函数.. 如果x^*是一个全局极小点, 当且仅当 $0 \in \partial f(x^*)$.
- 假设 f 是可微的, h 是凸函数(可能非光滑). 如果x^*是$f + h$ 的一个局部极小点, 当且仅当$-\nabla f(x^*) \in \partial h(x^*)$.

一般约束优化问题

$$\begin{aligned} \min_{x} \quad & f(x) \\ s.t. \quad & g_i(x) \le 0, i \in I, \\ & h_j(x) = 0, j \in E. \end{aligned}$$

最优值 f^*

拉格朗日函数

$$L(x,\lambda,\mu) = f(x) + \sum_{i \in I} \lambda_i g_i(x) + \sum_{j \in E} \mu_j h_j(x)$$

原始问题

$$\min_{x} \max_{\lambda \ge 0, \mu} L(x,\lambda,\mu)$$

对偶问题

$$\max_{\lambda \ge 0, \mu} \min_{x} L(x,\lambda,\mu)$$

最优值 q^*

$$L(x,\lambda,\mu)=f(x)+\sum_{i\in I}\lambda_i g_i(x)+\sum_{j\in E}\mu_j h_j(x)\le f(x)$$

≤ 0 $\quad$ $=0$

$$\max_{\lambda\ge 0,\mu}\min_{x} L(x,\lambda,\mu)\le \min_{x} f(x)$$

- **弱对偶定理: $q^*\le f^*$**
- **Lagrange 对偶问题是凸规划** $\quad \max_{\lambda\ge 0,\mu}\inf_{x} L(x,\lambda,\mu)$

$$\inf_{x} L\left(x,\alpha\lambda_1+(1-\alpha)\lambda_2,\alpha\mu_1+(1-\alpha)\mu_2\right)$$

$$\ge \alpha\inf_{x} L(x,\lambda_1,\mu_1)+(1-\alpha)\inf_{x} L(x,\lambda_2,\mu_2)$$

强对偶定理

$$\min_x \quad f(x)$$
$$s.t. \quad Ax \geq b, Cx = d.$$

目标函数为凸的，约束函数均为线性的 ＋ 最优值有限 → $f^* = q^*$

$$\min_x \quad f(x)$$
$$s.t. \quad g_i(x) \leq 0, i \in I,$$
$$Ax \geq b, Cx = d.$$

凸规划 ＋ Slater约束规格 ＋ 最优值有限 → $f^* = q^*$

↳ $\{x : g_i(x) < 0, i \in I, Ax \geq b, Cx = d\} \neq \varnothing$

凸二次规划 ＋ 最优值有限 → $f^* = q^*$ ＋ 原始问题和对偶问题最优解之间存在一一对应

线性规划

$$\min_{x} \quad c^T x$$
$$s.t. \quad Ax = b, x \geq 0.$$

$$\min_{x} \quad c^T x$$
$$s.t. \quad Ax \geq b, x \geq 0.$$

$$\min_{x,\gamma} \quad c^T x$$
$$s.t. \quad Ax - \gamma = b, x \geq 0, \gamma \geq 0.$$

拉格朗日对偶问题

$$\max_{y,z\geq 0} \min_{x} \quad c^T x - y^T (Ax - b) - z^T x$$

$$\Updownarrow \quad (c - A^T y - z)^T x + y^T b$$

$$c - A^T y = z \geq 0$$

$$\max_{y,z\geq 0,t\geq 0} \min_{x,\gamma} \quad c^T x - y^T (Ax - \gamma - b) - z^T x - t^T \gamma$$

$$c - A^T y = z \geq 0$$
$$y = t \geq 0$$

$$\max_{y} b^T y \quad s.t. \quad A^T y \leq c.$$

$$\max_{y} b^T y \quad s.t. \quad A^T y \leq c, y \geq 0$$

强凸二次规划

$$\min_x \ \frac{1}{2}x^TQx+c^Tx$$

$$s.t. \quad Ax=b, x\geq 0.$$

拉格朗日对偶问题

$$\max_{y,z\geq 0}\min_x \ \frac{1}{2}x^TQx+c^Tx-y^T\left(Ax-b\right)-z^Tx$$

$$\frac{1}{2}x^TQx+\left(c-A^Ty-z\right)^Tx+y^Tb$$

$$x=-Q^{-1}\left(c-A^Ty-z\right)$$

$$\max_{y,z\geq 0}-\frac{1}{2}\left(A^Ty+z-c\right)^TQ^{-1}\left(A^Ty+z-c\right)+y^Tb$$

练习：

$$\min_x \ \frac{1}{2}x^TQx+c^Tx$$

$$s.t. \quad Ax\geq b, x\geq 0.$$

硬间隔支持向量机

$$\min_{w,b} \ \frac{1}{2}\|w\|^2$$

$$s.t. \quad y_i\left(w^T x_i + b\right) \geq 1.$$

拉格朗日对偶问题

$$\max_{\alpha \geq 0} \min_{w,b} \ \frac{1}{2}\|w\|^2 - \sum_{i=1}^{N} \alpha_i \left(y_i\left(w^T x_i + b\right) - 1\right)$$

$$\max_{\alpha \geq 0} \ -\frac{1}{2}\sum_{i=1}^{N}\sum_{i=1}^{N} y_i y_j x_i^T x_i \alpha_i \alpha_j + \sum_{i=1}^{N} \alpha_i$$

$$s.t. \quad \sum_{i=1}^{N} \alpha_i y_i = 0.$$

练习：

$$\min_{w,b} \ \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{N} \xi_i$$

$$s.t. \quad y_i\left(w^T x_i + b\right) \geq 1 - \xi_i, \xi \geq 0.$$

Lasso问题

$$\min_{x} \frac{1}{2}\|Ax-b\|^2+\mu\|x\|_1$$

$$\min_{x,r} \frac{1}{2}\|r\|^2+\mu\|x\|_1$$

$$s.t. \quad Ax-b=r.$$

$$\max_{\lambda}\min_{x,r} \frac{1}{2}\|r\|^2+\mu\|x\|_1-\lambda^T(Ax-b-r)$$

$$r=-\lambda$$

$$A^T\lambda\in\mu\partial\left(\|x\|_1\right)$$

$$\max_{\lambda} b^T\lambda-\frac{1}{2}\|\lambda\|^2$$

$$s.t. \quad \left\|A^T\lambda\right\|_\infty\le\mu.$$

半定规划

$$\min_{X\in S^n} \ \langle C, X\rangle$$

$$s.t. \ \ \langle A_i, X\rangle = b_i, i = 1,2,\ldots,m,$$

$$X\text{半正定.}$$

拉格朗日对偶问题

$$\max_{y,S} \min_{X} \ \langle C, X\rangle - \sum_{i=1}^{m} y_i\left(\langle A_i, X\rangle - b_i\right) - \langle S, X\rangle$$

$$C - \sum_{i=1}^{m} y_i A_i - S = 0$$

$$\max_{y} \ \ b^T y$$

$$s.t. \ \ \sum_{i=1}^{m} y_i A_i - C + S = 0,$$

$$S\text{半正定.}$$

对偶理论

最大割问题

$$\max_{x} \ x^T Cx$$

$$s.t. \quad x_i^2 = 1, i = 1, 2, \ldots, n.$$

拉格朗日对偶问题

$$\max_{y} \min_{x} \ -x^T Cx + \sum_{i=1}^{n} y_i \left(x_i^2 - 1 \right)$$

$$\max_{y} \min_{x} \ x^T \left(Diag\left(y\right) - C \right) x - 1^T y$$

$$\min_{y} \ 1^T y$$

$$s.t. \quad Diag\left(y\right) - C \text{半正定}.$$

$$\max_{X} \min_{y} \ 1^T y - \left\langle Diag\left(y\right) - C, X \right\rangle$$

$$\max_{X} \min_{y} \ \sum_{i=1}^{n} \left(1 - X_{ii}\right) y_i + \left\langle C, X \right\rangle$$

$$\max_{y} \ \left\langle C, X \right\rangle$$

$$s.t. \quad X_{ii} = 1, i = 1, 2, \ldots, n,$$

$$X \text{半正定}.$$

练习：写出如下问题的对偶问题

$$\max_{x} \quad x^T Ax + 2b^T x$$
$$s.t. \quad \|x\| \le 1.$$

$$\max_{x} \quad \| X - ZV \|_F^2$$
$$s.t. \quad V^T V = I, Z^T 1 = 0.$$

对偶理论(Wolfe 对偶)

一般约束优化问题

$$\begin{aligned} \min_{x} \quad & f(x) \\ s.t. \quad & g_i(x) \le 0, i \in I, \\ & h_j(x) = 0, j \in E. \end{aligned}$$

最优值 f^*

Wolfe对偶问题

$$\begin{aligned} \max_{x,\lambda \ge 0,\mu} \quad & f(x) + \lambda^T g(x) + \mu^T h(x) \\ s.t. \quad & \nabla f(x) + \nabla g(x)^T \lambda + \nabla h(x)^T \mu = 0. \end{aligned}$$

最优值 q^*

即使原问题是凸规划, Wolfe 对偶问题通常是一非凸优化问题

对偶理论(Wolfe 对偶)

- **弱对偶定理**：若对任意的$\lambda, \mu, L(\cdot, \lambda, \mu)$在原问题和对偶问题可行域上是伪凸的, 则 $q^* \leq f^*$.
- **强对偶定理**：若对任意的$\lambda, \mu, L(\cdot, \lambda, \mu)$在原问题和对偶问题可行域上是伪凸的, 且GCQ 在最优解处成立, 则 $q^* = f^*$.
- **强对偶定理**: 若原问题是凸规划, 且$\nabla^2_{xx} L(x, \lambda, \mu)$非奇异或GCQ 在最优解处成立且 f 在最优解附近是严格凸的, 则$q^* = f^*$, 原始问题和对偶问题最优解之间存在一一对应。

对偶理论(Mond-Weir 对偶)

一般约束优化问题

$$\begin{aligned} \min_{x} \quad & f(x) \\ s.t. \quad & g_i(x) \le 0, i \in I, \\ & h_j(x) = 0, j \in E. \end{aligned}$$

最优值 f^*

Mond-Weir对偶问题

$$\begin{aligned} \max_{x,\lambda \ge 0,\mu} \quad & f(x) + \lambda^T g(x) + \mu^T h(x) \\ s.t. \quad & \nabla f(x) + \nabla g(x)^T \lambda + \nabla h(x)^T \mu = 0, \\ & \lambda^T g(x) + \mu^T h(x) \ge 0. \end{aligned}$$

最优值 q^*

即使原问题是凸规划, Mond-Weir对偶问题通常是一非凸优化问题

对偶理论(Mond-Weir 对偶)

- **弱对偶定理**：若对任意的$\lambda, \mu, L(\cdot, \lambda, \mu)$ 在原问题和对偶问题可行域上是伪凸的, $\lambda^T g(x) + \mu^T h(x)$ 在原问题和对偶问题可行域上是拟凸的, 则 $q^* \leq f^*$.

- **强对偶定理**：若对任意的$\lambda, \mu, L(\cdot, \lambda, \mu)$ 在原问题和对偶问题可行域上是伪凸的, $\lambda^T g(x) + \mu^T h(x)$ 在原问题和对偶问题可行域上是拟凸的, 且GCQ 在最优解处成立, 则 $q^* = f^*$.

- **强对偶定理**: 若对任意的$\lambda, \mu, L(\cdot, \lambda, \mu)$ 在原问题和对偶问题可行域上是伪凸的, $\lambda^T g(x) + \mu^T h(x)$ 在原问题和对偶问题可行域上是拟凸的, 且GCQ 在最优解处成立且 f 在最优解附近是严格凸的, 则$q^* = f^*$, 原始问题和对偶问题最优解之间存在一一对应。

切锥

给定可行域 X 及 $x \in X$, 若存在序列 $\{z_k\} \subset X$, $lim_{k\to\infty} z_k = x$ 以及正标量序列 $\{t_k\}$, $t_k \to 0$ 满足

$$\lim_{k\to\infty} (z_k - x)/t_k = d,$$

则称向量 d 为 X 在点 x 处的一个切向量. 所有点 x 处的切向量构成的集合称为切锥, 用 $T_X(x)$ 表示.

等价表述

存在序列 $\{d_k\}$, $\lim_{k\to\infty} d_k = d$ 以及正标量序列 $\{t_k\}$, $t_k \to 0$ 满足

$$x + t_k d_k \in X.$$

几何最优性条件

$$\min_x \ f(x)$$
$$s.t. \ \ g_i(x) \le 0, i \in I,$$
$$h_j(x) = 0, j \in E.$$

假设可行点 x^* 是上述问题的一个局部极小点. 如果 $f(x)$ 和 $g_i(x), i \in I, h_j(x), j \in E$ 在点 x^* 处是可微的, 那么

$$d^T \nabla f(x^*) \ge 0, \ \forall d \in T_X(x^*)$$

等价于

$$T_X(x^*) \cap \{d : \nabla f(x^*)^T d < 0\} = \varnothing.$$

Proof. 反证法，若 $T_\chi(x^*) \cap \{d \mid \nabla f(x^*)^T d < 0\} \neq \varnothing$, 取 $d \in T_\chi(x^*)$ 且 $f(x^*)^T d < 0.$

即存在序列 $\{d_k\}, \lim_{k\to\infty} d_k = d$ 以及正标量序列 $\{t_k\}, t_k \to 0$ 满足 $x + t_k d_k \in X.$

几何最优性条件

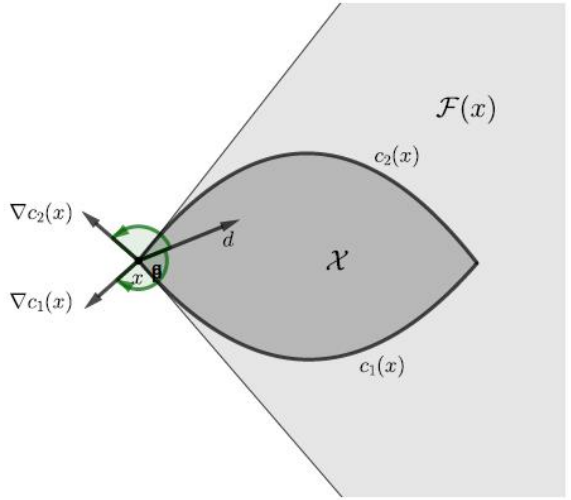
由于 $f(x^*)^T d < 0$，对于充分大的k, 我们有

$$
\begin{aligned}
& f(x^* + t_k d_k) = f(x^*) + t_k f(x^*)^T d_k + o(t_k) \\
& = f(x^*) + t_k f(x^*)^T d + t_k f(x^*)^T (d_k - d) + o(t_k) \\
& = f(x^*) + t_k f(x^*)^T d + o(t_k) \\
& < f(x^*)
\end{aligned}
$$

这与 x^* 的局部极小性矛盾.

线性可行锥

对于可行点 $x \in \chi$，定义该点的积极集 $\mathrm{A}(x) = E \cup \{i \in I : g_i(x) = 0\}$，点 x 处
的线性化可行方向锥定义为 $\mathrm{F}(x) = \left\{ d \;\middle|\; \begin{array}{ll} d^T \nabla h_j(x) = 0, & \forall j \in E \\ d^T \nabla g_i(x) \le 0, & \forall i \in \mathrm{A}(x) \cap I \end{array} \right\}$



定理：(线性化可行锥包含切锥)

设 $c_i(x),\ i \in E \cup I$ 一阶连续可微, 则对任意可行点 x 有 $T_\chi(x) \subseteq \mathrm{F}(x).$

证明：不妨设积极集 $\mathrm{A}(x) = E \cup I$，设 $d \in T_\chi(x)$，由定义

$$\lim_{k\to\infty} t_k = 0, \lim_{k\to\infty} \frac{z_k - x}{t_k} = d \Leftrightarrow z_k = x + t_k d + e_k$$

其残量 e_k 满足 $\|e_k\| = o(t_k)$. 对 $i \in E$，根据泰勒展开式，

$$\begin{aligned} 0 &= \frac{1}{t_k} c_i(z_k) \\ &= \frac{1}{t_k}\left(c_i(x) + \nabla c_i(x)^{\mathrm{T}}(t_k d + e_k) + o(t_k)\right) \\ &= \nabla c_i(x)^{\mathrm{T}} d + \frac{\nabla c_i(x)^{\mathrm{T}} e_k}{t_k} + o(1). \end{aligned}$$

线性化可行锥包含切锥

注意到 $\frac{\|e_k\|}{t_k} \to 0$. 令 $k \to \infty$, 即可得 $\nabla c_i(x)^{\mathrm{T}} d = 0, \quad i \in E.$

同理, 对 $i \in I$, 根据泰勒展开,

$$
\begin{aligned}
0 &\geq \frac{1}{t_k} c_i(z_k) \\
&= \frac{1}{t_k}\left(c_i(x) + \nabla c_i(x)^{\mathrm{T}}(t_k d + e_k) + o(t_k)\right) \\
&= \nabla c_i(x)^{\mathrm{T}} d + \frac{\nabla c_i(x)^{\mathrm{T}} e_k}{t_k} + o(1).
\end{aligned}
$$

注意到 $c_i(x) = 0, i \in I$ 因此我们有 $\nabla c_i(x)^{\mathrm{T}} d \leq 0, \quad i \in I.$

结合以上两点, 最终我们得到 $T_\chi(x) \subseteq \mathrm{F}\ (x).$

反例：切锥未必包含线性化可行锥

$$\min_x f(x) = x$$

$$s.t. \quad c(x) = -x + 3 \le 0$$

则 $T_\chi(3) = \{d \mid d \ge 0\}, \mathrm{F}(3) = \{d \mid d \ge 0\}.$

将上述约束条件改成 $c(x) = (-x+3)^3 \le 0,$ **因为可行域不变, 故** $x^* = 3$ **,切锥不变** $T_\chi(3) = \{d \mid d \ge 0\}.$

但由 $c'(x^*) = -3(x^* - 3)^2 = 0,$ **知线性化可行锥** $\mathrm{F}(3) = \{d \mid d \in R\}.$

此时 $T_\chi(x) \supset \mathrm{F}(x).$

约束优化最优性理论

口 约束品性的引入

- 线性化可行方向锥$\sqcup(x)$受可行域χ代数表示方式的影响。
- 切锥$T_{\chi}(x)$仅由可行域 χ 决定
- 线性可行化方向锥容易计算，但不能反映可行域χ的本质特征
- 切锥能反映可行域 χ 的本质特征，但不容易计算
- 引入约束品性来沟通两者，确保最优点x^{*}处$T_{\chi}(x^{*})=\mathrm{F}\ (x^{*}).$从而可以用 (x) 取代$T_{\chi}(x).$

口 定义（线性无关约束品性）

给定可行点 x，$\nabla g_{i}(x), i\in \mathbb{A}\ (x), \nabla h_{j}(x),\ j\in E$是线性无关的，则称**线性无关约束品性**（LICQ）在点 x 处成立.

口 定理

给定任意可行点$x\in\chi$，若在该点LICQ 成立，则有$_{\chi}(x)=\mathrm{F}\ (x).$

定义 (Mangasarian–Fromovitz 约束品性)

给定可行点 x 及相应的积极集 $\mathrm{A}(x)$. 如果存在一个向量 $w \in \mathrm{R}^n$, 使得

$$\nabla g_i(x)^T w < 0, \ \forall i \in \mathrm{A}(x)$$
$$\nabla h_j(x)^T w = 0, \ \forall j \in E,$$

并且等式约束对应的梯度集 $h_j(x), j \in E$ 是线性无关的, 则称点 x 处MFCQ 成立.

注：Mangasarian–Fromovitz 约束品性是 LICQ 的的一个常用推广, 简称为MFCQ.
注：LICQ 可以推出 MFCQ, 但是反过来不成立. 在 MFCQ 成立的情况下, 我们也可以证明 $T_\chi(x) = \mathrm{F}(x)$.

线性约束品性

- 另外一个用来保证 $T_\chi(x) = \mathrm{F}\ (x)$ 的约束品性是线性约束品性.

定义 (线性约束品性)

若所有的约束函数集$g_i(x),\ i \in I$ ，$h_j(x),\ j \in E$ 都是线性的, 则称线性约束品性成立.

- 当线性约束品性成立时, 也有 $T_\chi(x) = \mathrm{F}\ (x)$.

- 因此对只含线性约束的优化问题, 例如线性规划、二次规划, 很自然地有 $T_\chi(x) = \mathrm{F}\ (x)\ \forall\ x.$ 我们无需再关注约束函数的梯度是否线性无关.

- 一般来说, 线性约束品性和 LICQ 之间没有互相包含的关系.

线性约束品性

- 另外一个用来保证 $T_\chi(x) = \mathrm{F}\ (x)$ 的约束品性是线性约束品性.

定义 (线性约束品性)

若所有的约束函数集$g_i(x),\ i \in I$ ，$h_j(x),\ j \in E$ 都是线性的, 则称线性约束品性成立.

- 当线性约束品性成立时, 也有 $T_\chi(x) = \mathrm{F}\ (x)$.
- 因此对只含线性约束的优化问题, 例如线性规划、二次规划, 很自然地有 $T_\chi(x) = \mathrm{F}\ (x)\ \forall\ x.$ 我们无需再关注约束函数的梯度是否线性无关.
- 一般来说, 线性约束品性和 LICQ 之间没有互相包含的关系.

Karush-Kuhn-Tucker(KKT) 条件: 引入

- 回顾几何最优性条件: x^* 局部小 $\Leftrightarrow T_\chi(x^*)\cap\{d|\ \nabla f(x^*)^T d<0\}=\varnothing.$
- 当 $T_\chi(x^*)=\mathrm{F}\ (x^*)$ 时(约束品性成立), 上述条件变为

$$\left\{d\left|\begin{array}{c} d^T\nabla f(x^*)<0 \\ d^T\nabla h_j(x^*)=0,\quad j\in E \\ d^T\nabla g_i(x^*)\le 0,\quad i\in \mathrm{A}\ (x^*)\cap I \end{array}\right.\right\}=\varnothing.$$

- 上式依然难以验证, 但可使用Farkas 引理进行化简.

Farkas 引理

定理 (Farkas 引理)

设 p 和 q 为两个非负整数, 给定 $\mathbb{R}^n$ 中的向量 $\{a_i\}_{i=1}^p$, $\{b_i\}_{i=1}^q$ 和 c. 则满足:

$$d^{\mathrm{T}}a_i = 0,\ i = 1,\ 2,\ \cdots,\ p,\ d^{\mathrm{T}}b_i \geqslant 0,\ i = 1,\ 2,\ \cdots,\ q,\ d^{\mathrm{T}}c < 0$$

的 d 不存在当且仅当存在 $\{\lambda_i\}_{i=1}^p$ 和 $\mu_i \geqslant 0,\ i = 1,\ 2,\ \cdots,\ q$, 使得

$$c = \sum_{i=1}^{p} \lambda_i a_i + \sum_{i=1}^{q} \mu_i b_i.$$

从Farkas 引理到KKT 条件

- 由 Farkas 引理, 取 $a_j = \nabla h_j(x^*),\ i \in E,\ b_i = \nabla g_i(x^*),\ i \in \mathrm{A}(x^*) \cap I$ 以及 $c = -\nabla f(x^*)$, 则 $T_X(x^*) = F(x^*)$ 时几何最优性条件等价于:

$$-\nabla f(x^*) = \sum_{j \in E} \lambda_j^* \nabla h_j(x^*) + \sum_{i \in \mathrm{A}(x^*) \cap I} \lambda_i^* \nabla g_i(x^*),$$

其中 $\lambda_j^* \in \mathbb{R}, j \in E, \lambda_i^* \geq 0, i \in \mathrm{A}(x^*) \cap I.$

- 如果补充定义 $\lambda_i^* = 0,\ i \in I \setminus \hat{=} (x^*)$, 那么

$$-\nabla f(x^*) = \sum_{j \in E} \lambda_j^* \nabla h_j(x^*) + \sum_{i \in I} \lambda_i^* \nabla g_i(x^*),$$

- **互补松弛条件**: 对于任意的 $i \in I$, 我们注意到 $\lambda^*_i g_i(x^*) = 0, = 0.$ 这说明 $i \in \mathrm{A}(x^*) \cap I$ 时, λ^*_i =0或 $g_i(x^*)$=0至少出现一种, 当两种情况恰好只有一种满足时, 我们也称严格互补松弛条件.

KKT 条件总结:

假设 x^* 是一般优化问题的一个局部最优点. 如果

$$T_X(x^*) = F(x^*)$$

成立, 那么存在拉格朗日乘子 λ^*_i 和 μ^*_j 使得如下条件成立:

稳定性条件 $\nabla f(x^*) + \sum_{j \in E} u_j^* \nabla h_j(x^*) + \sum_{i \in I} \lambda_i^* \nabla g_i(x^*) = 0$

原始可行性条件 $h_j(x^*) = 0, \ \forall j \in E,$

原始可行性条件 $g_i(x^*) \leq 0, \ \forall i \in I,$

对偶可行性条件 $\lambda^*_i \geq 0, \ \forall i \in I,$

互补松弛条件 $\lambda^*_i g_i(x^*) = 0, \ \forall i \in I.$

二阶最优性条件: 引入

若 x^* 是满足 KKT 条件的点, 假设 $T_X(x^*) = F(x^*)$, 则 $\forall d \in F(x^*)$,

$$d^T \nabla f(x^*) = -\sum_{j \in E} \underbrace{\lambda_j^* d^T \nabla h_j(x^*)}_{=0} - \sum_{i \in A(x^*)} \underbrace{\lambda_i^* d^T \nabla g_i(x^*)}_{\leq 0} \geq 0,$$

此时一阶条件无法判断 x^* 是否是最优值点.

- 若 $d^T f(x^*) = 0$, 则需要利用二阶信息来进一步判断在其可行邻域内的目标函数值.
- 拉格朗日函数在这些方向上的曲率即可用来判断 x^* 的最优性.
- 首先引入临界锥来精确刻画这些方向.

临界锥

定义 (临界锥)

设 (x^*, λ^*) 是满足 KKT 条件的 KKT 对, 定义临界锥为

$$C(x^*, \lambda^*) = \{d \in F(x^*) \mid \nabla g_i(x^*)^T d = 0,\ \forall i \in \mathrm{A}(x^*) \cap I, \lambda^*_i > 0\},$$

其中 $F(x^*)$为点 x^*处的线性化可行方向锥.

- 临界锥是线性化可行方向锥 $F(x^*)$ 的子集.
- 沿着临界锥中的方向进行优化, 所有等式约束和 $\lambda^*_i > 0$对应的不等式约束(此时这些不等式均取等) 都会尽量保持不变.
- 当 $d \in \mathrm{C}(x^*, \lambda^*)$ 时, $\forall i \in I$ 有 $\lambda^*_i \nabla g_i(x^*)^T d = 0$, $\forall j \in E$ 有

$$d^T \nabla f(x^*) + \sum_{j \in E} \lambda_j^* d^T \nabla h_j(x^*) + \sum_{i \in I} \lambda_i^* d^T \nabla g_i(x^*) = 0,$$

二阶最优性条件

定理 (二阶最优性条件)

必要性: 假设 x^* 是问题的一个局部最优解, 并且 $T_X(x^*) = F(x^*)$成立. 令 λ^*，μ^* 为相应的拉格朗日乘子, 即 (x^*, λ^*, μ^*) 满足 KKT 条件, 那么

$$d^T \nabla_{xx}^2 L(x^*, \lambda^*, \mu^*) d \geq 0, \quad \forall d \in \mathrm{C}(x^*, \lambda^*).$$

充分性: 假设在可行点 x^* 处, 存在一个拉格朗日乘子 λ^*，μ^*, 使得即 (x^*, λ^*, μ^*)满足 KKT 条件. 如果

$$d^T \nabla_{xx}^2 L(x^*, \lambda^*, \mu^*) d \geq 0, \quad \forall d \in \mathrm{C}(x^*, \lambda^*), d \neq 0.$$

那么 x^* 为问题的一个严格局部极小解.

约束优化的最优性理论: 例子

$$\min\ x_1^2 + x_2^2, \quad \text{s.t.} \quad \frac{x_1^2}{4} + x_2^2 - 1 = 0,$$

其拉格朗日函数为

$$L(x, \lambda) = x_1^2 + x_2^2 + \lambda\left(\frac{x_1^2}{4} + x_2^2 - 1\right).$$

该问题可行域在任意一点 $x = (x_1, x_2)^{\mathrm{T}}$ 处的线性化可行方向锥为

$$\mathrm{F}\ (x) = \{(d_1, d_2) | \frac{x_1}{4} d_1 + x_2 d_2 = 0\}.$$

因为只有一个等式约束且其对应函数的梯度非零, 故有 LICQ 成立, 于是$T_{\mathrm{X}}\ (x) = F(x)$,若 (x, λ) 为 KKT 对, 无不等式约束, 故 $C(x, \lambda) = F(x)$.

可以计算出其 4 个 KKT 对

$(x^T, \lambda) = (2, 0, -4), (-2, 0, -4), (0, 1, -1)$ 和 $(0, -1, -1)$.

约束优化的最优性理论: 例子

考虑第一个 KKT 对$y = (2, 0, -4)^{\mathrm{T}}$, 计算可得

$$\nabla^2_{xx} L(y) = \begin{bmatrix} 0 & 0 \\ 0 & -6 \end{bmatrix}, \quad \mathrm{C}(y) = \{(d_1, d_2) \mid d_1 = 0\}.$$

取 $d = (0, 1)$, 则 $d^T \nabla^2_{xx} L(y) d = -6 < 0$, 因此 y 不是局部最优点. 类似地, 对第三个 KKT 对 $z = (0, 1, -1)$,

$$\nabla^2_{xx} L(z) = \begin{bmatrix} \frac{3}{2} & 0 \\ 0 & 0 \end{bmatrix}, \quad \mathrm{C}(z) = \{(d_1, d_2) \mid d_2 = 0\}.$$

对于任意的 $d = (d_1, 0)$ 且 $d_1 \neq 0$, $d^T \nabla^2_{xx} L(z) d = \frac{3}{2} d_1^2 > 0$

因此, z 为一个严格局部最优点.

凸规划的最优性条件

- 前述问题都可以写为

$$\begin{aligned} \min_{x\in \mathrm{D}} \quad & f(x), \\ \text{s.t.} \quad & g_i(x) \le 0, \quad i = 1, 2, \cdots, m, \\ & Ax = b, \end{aligned}$$

其中 $f(x)$ 为适当的凸函数, $\forall i$, $g_i(x)$ 是凸函数且 $\mathrm{dom} c_i = \mathrm{R}^n$.

- 自变量 x 还受约束的限制, 定义可行域

$$\mathrm{X} = \{x \in \mathrm{D} : g_i(x) \le 0,\ i = 1,\ 2,\ \cdots,\ m;\ Ax = b\}.$$

- 由于凸优化问题的可行域是凸集, 因此等式约束只能是线性约束.

Slater 约束品性与强对偶原理: 相对内点

首先给出集合 D 的相对内点集 **relint**D 的定义. 给定集合 D, 记其仿射包为

$$\text{affine } D=\{x|\ x=\theta_1 x_1+\theta_2 x_2+\cdots+\theta_k x_k,\ x_1,x_2,\cdots,x_k\in D,\ \sum_{i=1}^{k}\theta_i=1\}.$$

定义 (相对内点)

集合D 的相对内点集定义为

$$\textbf{relint}\mathrm{D}=\{x\in \mathrm{D}\mid \exists r>0,\text{使得}B(x,r)\cap \textbf{affine}\mathrm{D}\subseteq \mathrm{D}\}.$$

相对内点是内点的推广, 若 D 本身的“维数”较低, 则 D 不可能有内点, 但如果在它的仿射包 **affine**D 中考虑, 则 D 可能有相对内点.

Slater 约束品性

定义 (Slater 约束品性)若存在 $x \in \mathbf{relint}\mathrm{D}$ 满足

$$c_i(x) < 0,\ i = 1,\ 2,\ \cdots,\ m,\ Ax = b,$$

则称对此问题 Slater 约束品性满足. 该约束品性也称为 Slater **条件**.

- **affine**$\mathrm{D} = \mathrm{R}^n$ 时相对内点就是内点.

- 不等式约束是仿射函数时, Slater 条件可以放宽. 设前 k 个不等式约束是仿射的, 此时 Slater 约束品性变为: 存在 $x \in \mathbf{relint}\mathrm{D}$, 满足

$$g_i(x) \le 0,\ i = 1,\ 2,\ \cdots,\ k;\ c_i(x) < 0,\ i = k+1,\ k+2\ \cdots,\ m;\ Ax = b,$$

即对线性不等式约束无需要求其存在严格可行点.

一阶充要条件

- 特定约束品性, 乘子的存在性. 而对于凸优化问题, 当 Slater 条件满足时, KKT 条件则变为局部最优解的充要条件.

定理 (凸优化问题的一阶充要条件)

对于凸优化问题, 用 a_i 表示矩阵 A^{T} 的第 i 列, ∂f, ∂c_i 表示次梯度, 如果 *Slater*条件成立, 那么 x^*, λ^* 分别是原始, 对偶全局最优解当且仅当

稳定性条件 $0 \in \partial f(x^*) + \sum_{i \in I} \lambda_i^* \partial g_i(x^*) + \sum_{i \in E} \lambda_i^* a_i$

原始可行性条件 $Ax^* = b$

原始可行性条件 $g_i(x^*) \leq 0, \ \forall i \in I,$

对偶可行性条件 $\lambda_i^* \geq 0, \ \forall i \in I,$

互补松弛条件 $\lambda_i^* g_i(x^*) = 0, \ \forall i \in I.$

一阶充要条件:充分性

设存在 $(\bar{x},\bar{\lambda})$ 满足 KKT 条件, 我们考虑凸优化问题的拉格朗日函数

$$L(x,\lambda)=f(x)+\sum_{i\in I}\lambda_i g_i(x)+\sum_{i\in E}\lambda_i\left(a_i^{\mathrm{T}}x-b_i\right).$$

当固定 $\lambda=\bar{\lambda}$ 时, 注意到 $\bar{\lambda}_i>0, i\in I$ 以及 $\bar{\lambda}_i(a_i^T x), i\in E$是线性函数可知 $L(x,\bar{\lambda})$

是关于 x 的凸函数.
由凸函数全局最优点一阶充要性可知, 此时 $\bar{x}$ 是$L(x,\bar{\lambda})$的全局极小点. 根据拉格朗日对偶函数的定义, $L(\bar{x},\bar{\lambda})=\inf_{x\in \mathrm{D}} L(x,\bar{\lambda})=d(\bar{\lambda}).$

根据原始可行性条件 $A\bar{x}=b$ 以及互补松弛条件 $\bar{\lambda}_i g_i(\bar{x}), i\in I,$

$$L(\bar{x},\bar{\lambda})=f(\bar{x})+0+0=f(\bar{x}).$$

根据弱对偶原理, 故 $\bar{x},\bar{\lambda}$ 分别是原始问题和对偶问题的最优解.

$$L(\bar{x}^*,\bar{\lambda})=f(\bar{x}^*)>p^*>d^*\geq d(\bar{\lambda})=L(\bar{x},\bar{\lambda})>p^*=d^*.$$

例子

example:water-filling (assume$\alpha_i > 0$)

$$\begin{aligned} \min \quad & \sum_{i=1}^{n} \log(x_i + \alpha_i) \\ \text{s.t.} \quad & x \geq 0, \quad \mathbf{1}^T x = 1 \end{aligned}$$

x is optimal iff $x \geq 0$, $1^T x = 1$, and there exist $\lambda \in \mathrm{R}^n$, $v \in \mathrm{R}$ such that

$$\lambda_i \geq 0, \quad \lambda_i x_i = 0, \quad \frac{1}{x_i + \alpha_i} + \lambda_i = v$$

- if $v < 1/\alpha_i$: $\lambda_i = 0$ and $x_i = 1/v - \alpha_i$
- if $v \geq 1/\alpha_i$: $\lambda_i = v - 1/\alpha_i$ and $x_i = 0$

- determine v from $\mathbf{1}^T x = \sum_{i=1}^{n} \max\left\{0, \frac{1}{v} - \alpha_i\right\} = 1$

约束优化最优性理论

非光滑凸优化实例:基追踪问题

$$\min_{x\in\mathbb{R}^n} \|x\|_1, \quad \text{s.t. } Ax=b. \Leftrightarrow \begin{aligned} \min \ & \sum_i x_i^+ + x_i^-, \\ \text{s.t} \ & Ax^+ - Ax^- = b, \\ & x^+, x^- \geq 0. \end{aligned} \Leftrightarrow \begin{aligned} \min_{y\in\mathbb{R}^{2n}} \ & \mathbf{1}^T y, \\ \text{s.t.} \ & [A,-A]y = b, \\ & y \geq 0. \end{aligned}$$

根据一般线性规划问题的最优性条件, 求解基追踪问题等价于求解

$$\begin{cases} \mathbf{1} + [A,-A]^{\mathrm{T}} \nu^* - s^* = 0, \\ [A,-A]y^* = b, \\ y^* \geq 0, \\ s^* \geq 0, \\ s^* \odot y^* = 0, \end{cases}$$

非光滑凸优化实例:基追踪问题

- 拉格朗日函数: $L(x, v) = \|x\|_1 + v^{\mathrm{T}}(Ax - b)$.
- x^* 为全局最优解当且仅当存在 $v* \in \mathrm{R}^m$ 使得
$$0 \in \partial \|x^*\|_1 + A^{\mathrm{T}}v^*, \text{ 且 } b = Ax^*.$$
- 令 $x_i^* = y_i^* - y_{n+i}^*$, $i = 1, 2, \cdots, n$, 则
$$[A, -A]y^* = b \Rightarrow Ax^* = b.$$
- 对于等式 $1 + [A, -A]^{\mathrm{T}}v^* - s^* = 0$, 我们有
$$(A^{\mathrm{T}}v^*)_i = -1 + s_i^* = 1 - s_{n+i}^*, \quad i = 1, 2, \cdots, n.$$
因此, $s_i^* + s_{n+i}^* = 2$. 根据互补条件, y_i^*, y_{n+i}^* 至少有一个为 0.

约束优化最优性理论

基追踪问题最优性条件: 直接推导

- 若 $x_i^* = 0$, 则有 $y_i^* = y_{n+i}^* = 0$. 由 $s_i^*, s_{n+i}^* \geq 0$ 知 $(A^{\mathrm{T}}v^*)_i \in [-1, 1]$.
- 若 $x_i^* < 0$, 则有 $y_i^* = 0$, $y_{n+i}^* > 0$, 此时有 $(A^{\mathrm{T}}v^*)_i = 1$.
- 对于 $x_i^* > 0$, 我们有 $(A^{\mathrm{T}}v^*)_i = -1$.
- 以上过程均可逆推, 这就证明了利用非光滑凸优化理论推导的最优性条件和利用线性规划推导的最优性条件是等价的.

感谢观看

大数据优化：理论、算法及其应用

主讲人：彭振华

数学与计算机学院

2026年