南昌大学
NANCHANG UNIVERSITY

大数据优化：理论、算法及其应用

主讲人：彭振华

数学与计算机学院

2026年

约束优化算法

第六部分

内点罚函数法

外点罚函数法

增广拉格朗日函数法

约束优化问题

考虑约束优化问题：

$$\min_{x} \quad f(x)$$
$$s.t. \quad x \in \chi. \tag{66}$$

其中，χ 为 x 的可行域. 相比于无约束问题的困难：

- 约束优化问题中 x 不能随便取值，梯度下降法所得点不一定在可行域内
- 最优解处目标函数的梯度不一定为零向量

为了解决这些困难，考虑使用罚函数法将约束优化问题转化为无约束优化问题处理

约束优化问题

罚函数法的思想是将约束优化问题(66) 转化为无约束优化问题来进行求解.

- 为了保证解的逼近质量，无约束优化问题的目标函数为原约束优化问题的目标函数加上与约束函数有关的惩罚项.

- 对于可行域外的点，惩罚项为正，即对该点进行惩罚；对于可行域内的点，惩罚项为0，即不做任何惩罚. 因此，惩罚项会促使无约束优化问题的解落在可行域内. 并且只要落在可行域内，那么其就是原约束优化问题的解.

- 罚函数一般由约束部分乘正系数组成，通过增大该系数，我们可以更严厉地惩罚违反约束的行为，从而迫使惩罚函数的最小值更接近约束问题的可行区域.

口 等式约束的二次罚函数法

首先考虑简单情形：仅包含等式约束的约束优化问题

$$\min_{x} \quad f(x)$$
$$s.t. \quad c_i(x) = 0, \qquad \forall i \in \varepsilon.$$

其中$x \in \mathrm{R}^n$，ε 为等式约束的指标集，$c_i(x)$ 为连续函数定义该问题的二次罚函数为:

$$P_E(x,\sigma) = f(x) + \frac{1}{2}\sigma \sum_{i \in \mathrm{E}} c_i^2(x) \tag{68}$$

其中等式右端第二项称为**罚函数**，$\sigma > 0$ 称为**罚因子**

- 由于这种罚函数对不满足约束的点进行惩罚 在迭代过程中点列一般处于可行域之外，因此它也被称为**外点罚函数**.

例1

为了直观理解罚函数的作用，我们给出一个例子:
考虑优化问题

$$\begin{aligned} \min \quad & x+\sqrt{3}y \\ \text{s.t.} \quad & x^2+y^2=1 \end{aligned}$$

容易求得最优解为 $\left(-\frac{1}{2},\ -\frac{\sqrt{3}}{2}\right)$. 考虑二次罚函数

$$P_E(x,y,\sigma)=x+\sqrt{3}y+\frac{\sigma}{2}\left(x^2+y^2-1\right)^2$$

并在下图中绘制出 $\sigma=1$ 和 $\sigma=10$ 对应的罚函数的等高线.

例1

取不同的值时二次罚函数 $P_E(x, y, \sigma)$ 的等高线

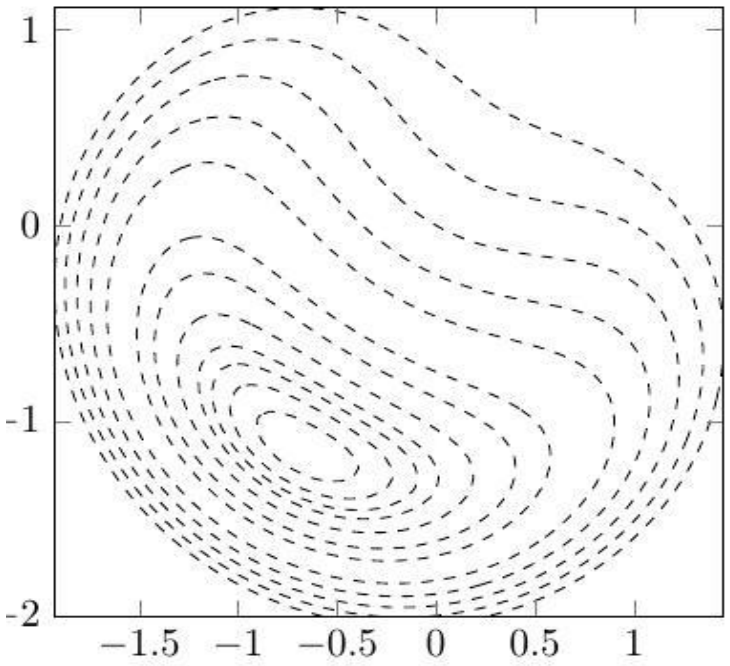


Figure: (a) $\sigma = 1$

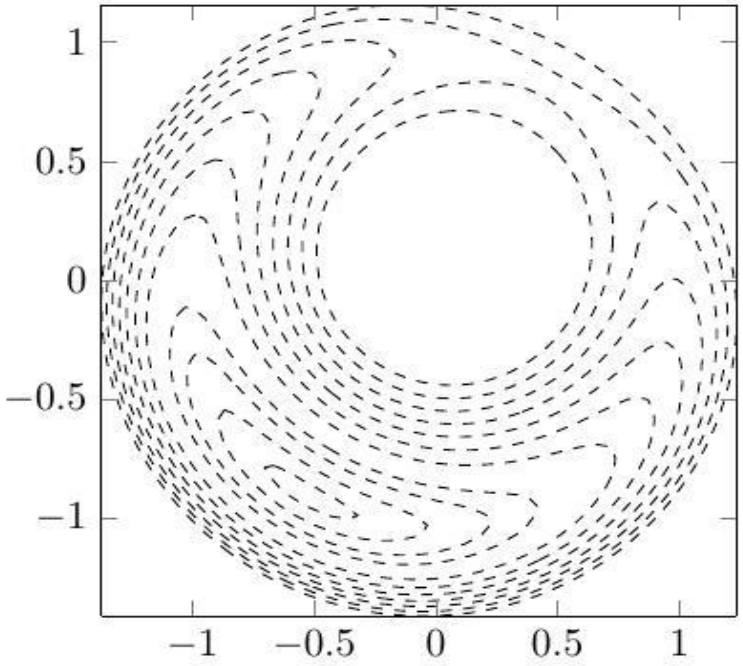


Figure: (b) $\sigma = 10$

例2

下面这个例子表明，当 σ 选取过小时罚函数可能无下界.
考虑优化问题

$$\begin{aligned} \min \quad & -x^2+2y^2 \\ \text{s.t.} \quad & x=1 \end{aligned}$$

容易求得最优解为 $(1,0)^T$，然而考虑罚函数

$$P_E(x,y,\sigma)=-x^2+2y^2+\frac{\sigma}{2}(x-1)^2$$

对任意的 $\sigma \le 2$，该罚函数无下界

口 二次罚函数法算法

Algorithm 9 二次罚函数法

1: 给定 $\sigma_1 > 0, x_0, k \leftarrow 1$. 罚因子增长系数 $\rho > 1$.
2: **while** 未达到收敛准则 **do**
3: 以 x^k 为初始点，求解 $x^{k+1} = \arg\min_x P_E(x, \sigma_k)$
4: 选取 $\sigma^{k+1} = \rho\sigma_k$.
5: $k \leftarrow k + 1$
6: **end while**

- 选取合适的参数 ρ: σ_k 增长过快会使子问题求解困难，σ_k 增长过慢则会增加迭代次数. 另外，也可以自适应地调整 ρ
- 检测到迭代点发散就应该立即终止迭代并增大罚因子
- 为保证收敛，子问题求解误差需要趋于零

二次罚函数法算法

从 KKT 条件角度分析： 原问题的 KKT 条件：

$$\nabla f(x^*) - \sum_{i \in \mathrm{E}} \lambda_i^* \nabla c_i(x^*) = 0$$

$$c_i(x^*) = 0, \quad \forall i \in \mathrm{E}$$

添加罚函数项问题的 KKT 条件：

$$\nabla f(x) + \sum_{i \in \mathrm{E}} \sigma c_i(x) \nabla c_i(x) = 0$$

假设两个问题收敛到同一点，对比 KKT 条件 (梯度式)，应有下式成立：

$\sigma c_i(x) \approx -\lambda_i^* \quad \forall i \in \varepsilon$

最优点处乘子 λ^* 固定，为使约束 $c_i(x) = 0$ 成立，需要 $\sigma \to \infty$

二次罚函数法算法

从 KKT 条件角度分析： 原问题的 KKT 条件：

$$\nabla f(x^*) - \sum_{i \in \mathrm{E}} \lambda_i^* \nabla c_i(x^*) = 0$$

$$c_i(x^*) = 0, \quad \forall i \in \mathrm{E}$$

添加罚函数项问题的 KKT 条件：

$$\nabla f(x) + \sum_{i \in \mathrm{E}} \sigma c_i(x) \nabla c_i(x) = 0$$

假设两个问题收敛到同一点，对比 KKT 条件 (梯度式)，应有下式成立：

$\sigma c_i(x) \approx -\lambda_i^* \quad \forall i \in \varepsilon$

最优点处乘子 λ^* 固定，为使约束 $c_i(x) = 0$ 成立，需要 $\sigma \to \infty$

口 二次罚函数法算法

- 考虑罚函数 $P_E(x, \sigma)$ 的海瑟矩阵:

$$\nabla^2_{xx} P_E(x,\sigma) = \nabla^2 f(x) + \sum_{i\in \mathrm{E}} \sigma c_i(x) \nabla^2 c_i(x) + \sigma \nabla c_i(x) \nabla c_i(x)^{\mathrm{T}}$$

- 等号右边的前两项可以使用拉格朗日函数 $L(x, \lambda^*)$ 来近似，即:

$$\nabla^2_{xx} P_E(x,\sigma) \approx \nabla^2_{xx} L(x,\lambda^*) + \sigma \nabla c(x) \nabla c(x)^{\mathrm{T}}$$

- 右边为一个定值矩阵和一个最大特征值趋于正无穷的矩阵，这导致 $\nabla^2_{xx} P_E(x,\sigma)$ 条件数越来越大，求解子问题的难度也会相应地增加.

- 此时使用梯度类算法求解将会变得非常困难．若使用牛顿法，则求解牛顿方程本身就是一个非常困难的问题．因此在实际应用中，我们不可能令罚因子趋于正无穷.

口 分析数值困难

- 考虑罚函数 $P_E(x, \sigma)$ 的海瑟矩阵:

$$\nabla_{xx}^2 P_E(x,\sigma) = \nabla^2 f(x) + \sum_{i\in \mathrm{E}} \sigma c_i(x) \nabla^2 c_i(x) + \sigma \nabla c_i(x) \nabla c_i(x)^{\mathrm{T}}$$

- 等号右边的前两项可以使用拉格朗日函数 $L(x, \lambda^*)$ 来近似，即:

$$\nabla_{xx}^2 P_E(x,\sigma) \approx \nabla_{xx}^2 L(x,\lambda^*) + \sigma \nabla c(x) \nabla c(x)^{\mathrm{T}}$$

- 右边为一个定值矩阵和一个最大特征值趋于正无穷的矩阵，这导致 $\nabla_{xx}^2 P_E(x,\sigma)$ 条件数越来越大，求解子问题的难度也会相应地增加.

- 此时使用梯度类算法求解将会变得非常困难．若使用牛顿法，则求解牛顿方程本身就是一个非常困难的问题．因此在实际应用中，我们不可能令罚因子趋于正无穷.

收敛性分析

定理（二次罚函数法的收敛性 1）

设 x^{k+1} 是 $P_E(x, \sigma_k)$ 的全局极小解，σ_k 单调上升趋于无穷，则 x^k 的每个极限点 x^* 都是原问题的全局极小解.

证明. 设 $\bar{x}$ 原问题的极小解. 由x^{k+1}是 $P_E(x, \sigma_k)$ 的全局极小解，得 $P_E(x^{k+1}, \sigma_k) \leq P_E(\bar{x}, \sigma_k)$,

即 $$f\left(x^{k+1}\right)+\frac{\sigma_k}{2}\sum_{i\in E} c_i^2\left(x^{k+1}\right) \leq f(\bar{x})+\frac{\sigma_k}{2}\sum_{i\in E} c_i^2(\bar{x}) = f(\bar{x}).$$

整理得

$$\sum_{i\in E} c_i^2\left(x^{k+1}\right) \leq \frac{2}{\sigma_k}\left(f(\bar{x})-f\left(x^{k+1}\right)\right).$$

设 x^* 是 x^k 的一个极限点，不妨 $x^k \to x^*$。在(70)式中令$k \to \infty$，得$\sum_{i\in E} c_i^2\left(x^*\right)=0.$ 由此易 知 ， x^*为 原 问题得可行解。又由(69)式知 $f\left(x^{k+1}\right) \leq f(\bar{x})$, 取极限得$f\left(x^*\right) \leq f(\bar{x}).$

收敛性分析

定理（二次罚函数法的收敛性 2）

设 $f(x)$ 与 $c_i(x)$ $(i \in \varepsilon)$ 连续可微，正数序列 $\varepsilon_k \to 0, \sigma_k \to +\infty.$

在算法9 中，子问题的解 x^{k+1} 满足 $\left\|\nabla_x P_E(x^{k+1}, \sigma_k)\right\| \leqslant \varepsilon_k$，而对 x^k 的任何极限点 x^*，都有 $\{\nabla c_i(x^*), i \in \varepsilon\}$ 线性无关，则 x^* 是等式约束最优化问题(67) 的KKT 点，且

$$\lim_{k\to\infty}\left(-\sigma_k c_i\left(x^{k+1}\right)\right) = \lambda_i^*, \quad \forall i \in \mathrm{E}$$

其中 λ_i^* 是约束 $c_i(x^*) = 0$ 对应的拉格朗日乘子.

定理证明

Proof. 容易求出$P_E(x, \sigma_k)$的梯度为

$$\nabla P_E\left(x,\sigma_k\right)=\nabla f(x)+\sum_{i\in \mathrm{E}}\sigma_k c_i(x)\nabla c_i(x). \tag{71}$$

根据子问题求解的终止准则，对 x_{k+1} 我们有

$$\left\|\nabla f\left(x^{k+1}\right)+\sum_{i\in \mathrm{E}}\sigma_k c_i\left(x^{k+1}\right)\nabla c_i\left(x^{k+1}\right)\right\|\le \varepsilon_k. \tag{72}$$

利用三角不等式，得

$$\left\|\sum_{i\in \mathrm{E}} c_i\left(x^{k+1}\right)\nabla c_i\left(x^{k+1}\right)\right\|\le \frac{1}{\sigma_k}\left(\varepsilon_k+\left\|\nabla f\left(x^{k+1}\right)\right\|\right). \tag{73}$$

不妨设$\{x^k\}$收敛于x^*，在(73) 式中令$k\to\infty$，由 $f(x),c_i(x)$连续性可知 $\sum_{i\in \mathrm{E}} c_i(x^*)\nabla c_i(x^*).$

又由$\{\nabla c_i(x^*), i\in\varepsilon\}$ 线性无关，故$c_i(x^*)=0.$ 即x^*为一个可行点.

定理证明

Proof. 下面说明x^*满足KKT 条件中的梯度条件

记 $\nabla c(x)=\left[\nabla c_i(x)\right]_{i\in \mathrm{E}}$， $\lambda_i^k=-\sigma_k c_i(x^{k+1})$， $\lambda^k=\left(\lambda_1^k,\lambda_2^k,\ldots,\lambda_{|\mathrm{E}|}^k\right)^T$

则梯度式(71) 可改写为 $\nabla c\left(x^{k+1}\right)\lambda^k=\nabla f\left(x^{k+1}\right)-\nabla P_E\left(x^{k+1},\sigma_k\right)$

由条件知 $\nabla c(x^*)$ 是列满秩矩阵，而 $x^k\to x^*$，故由广义逆得到

$$\lambda^k=\left(\nabla c\left(x^{k+1}\right)^{\mathrm{T}}\nabla c\left(x^{k+1}\right)\right)^{-1}\nabla c\left(x^{k+1}\right)^{\mathrm{T}}\left(\nabla f\left(x^{k+1}\right)-\nabla xP_E\left(x^{k+1},\sigma_k\right)\right)$$

等式两侧关于k 取极限，得

$$\lambda^*\overset{\mathrm{def}}{=}\lim_{k\to\infty}\lambda^k=\left(\nabla c(x^*)^{\mathrm{T}}\nabla c(x^*)\right)^{-1}\nabla c(x^*)^{\mathrm{T}}\nabla f(x^*).$$

最后在梯度表达式(71) 中令 $k\to\infty$ 可得 KKT 条件中的梯度条件成立，λ^* 就是点 x^* 对应的拉格朗日乘子.

一般约束问题的二次罚函数法

考虑不等式约束问题：

$$\min_x \ f(x)$$
$$s.t. \ c_i(x) \le 0, \qquad \forall i \in \mathrm{I}.$$

定义该问题的二次罚函数为：

$$P_I(x,\sigma) = f(x) + \frac{1}{2}\sigma \sum_{i\in \mathrm{I}} \tilde{c}_i^2(x)$$

其中$\tilde{c}_i(x)$ 定义为：

$$\tilde{c}_i(x) = \max\{c_i(x), 0\}$$

注：$h(t) = (\min\{t, 0\})^2$ 关于 t 可导，故$P_I(x, \sigma)$梯度存在，所以可以使用梯度类算法求解，或者考虑能处理不可微情形的二阶算法，如半光滑牛顿法等。

一般约束问题的二次罚函数法

考虑一般约束问题：

$$\begin{aligned} &\min_{x} \quad f(x) \\ &s.t. \quad c_i(x) = 0, \qquad \forall i \in \varepsilon. \\ &\qquad c_i(x) \le 0, \qquad \forall i \in \mathrm{I}. \end{aligned}$$

定义该问题的二次罚函数为：$P(x,\sigma) = f(x) + \frac{1}{2}\sigma\left[\sum_{i\in \mathrm{E}} c_i^2(x) + \sum_{i\in \mathrm{I}} \tilde{c}_i^2(x)\right]$

其中等式右端第二项称为惩罚项，$\sigma > 0$ 称为罚因子.

二次罚函数法的优缺点

优点:

- 将约束优化问题转化为无约束优化问题，当$c_i(x)$光滑时可以调用一般的无约束光滑优化问题算法求解.
- 二次罚函数形式简洁直观而在实际中广泛使用.

缺点:

- 需要$\sigma \to \infty$，此时海瑟矩阵条件数过大，对于无约束优化问题的数值方法拟牛顿法与共轭梯度法存在数值困难，且需要多次迭代求解子问题.
- 对于存在不等式约束的$P_E(x, \sigma)$可能不存在二次可微性质，光滑性降低.
- 不精确，与原问题最优解存在距离.(后面将介绍精确罚函数法)

应用举例——LASSO 问题

考虑LASSO 问题，

$$\min_x \quad \frac{1}{2}\| Ax-b\|^2+\mu\|x\|_1$$

以及基追踪（BP）问题，

$$\min_x \quad \|x\|_1$$

$$\text{s.t.} \quad Ax=b$$

写成二次罚函数法形式，

$$\min_x \quad \|x\|_1+\frac{\sigma}{2}\| Ax-b\|^2$$

观察：

- 仅在 μ 趋于0 时，LASSO 问题的解收敛于BP 问题的解
- μ 较小时问题病态，收敛较慢，可逐渐缩小 μ 的值求解子问题逼近

LASSO 问题罚函数法算法

Algorithm 10 LASSO 问题的二次罚函数法

1: 给定初值 x_0，最终参数 μ，初始参数 μ_0，因子 $\gamma \in (0,1), k \leftarrow 0$.
2: **while** $\mu_k \geq \mu$ **do**
3: 以 x^k 为初值，求解问题 $x^{k+1} = \arg\min_x \left\{ \frac{1}{2}\|Ax-b\|^2 + \mu_k \|x\|_1 \right\}$
4: **if** $\mu_k = \mu$ **then**
5: 停止迭代，输出 x^{k+1}
6: **else**
7: 更新罚因子 $\mu_{k+1} = \max\{\mu, \gamma\mu_k\}$
8: $k \leftarrow k+1$
9: **end if**
10: **end while**

LASSO 问题——对比罚函数法和次梯度法

图展示了分别使用罚函数法和次梯度法求解 LASSO 问题的结果，取 LASSO 问题的正则化参数为 $\mu = 10^{-3}$．在罚函数法中，令 μ 从 10 开始，因子 $\gamma = 0.1$，次梯度法选取固定步长 $\alpha = 0.0002$.

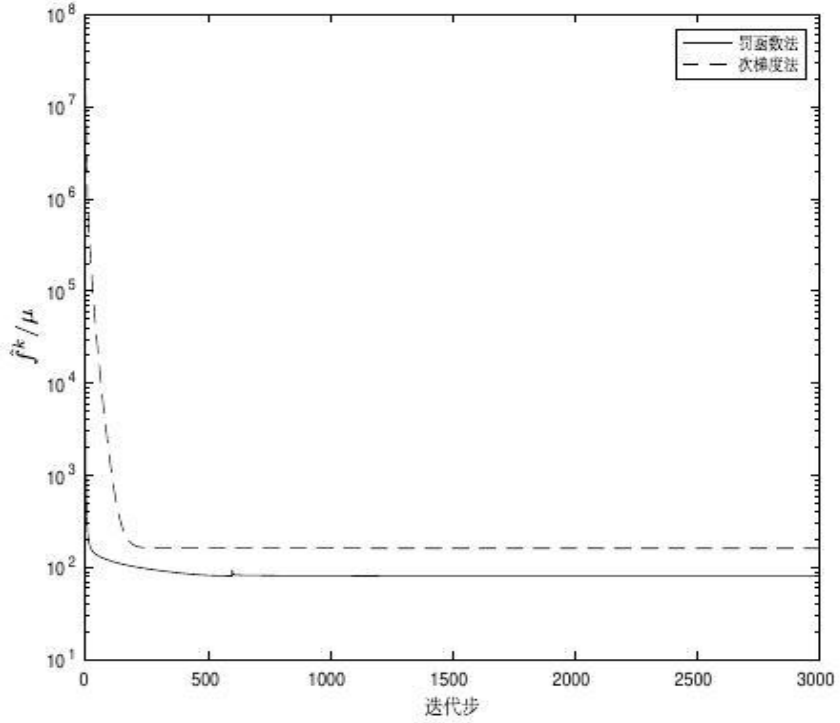


Figure: (a) 函数值变化趋势

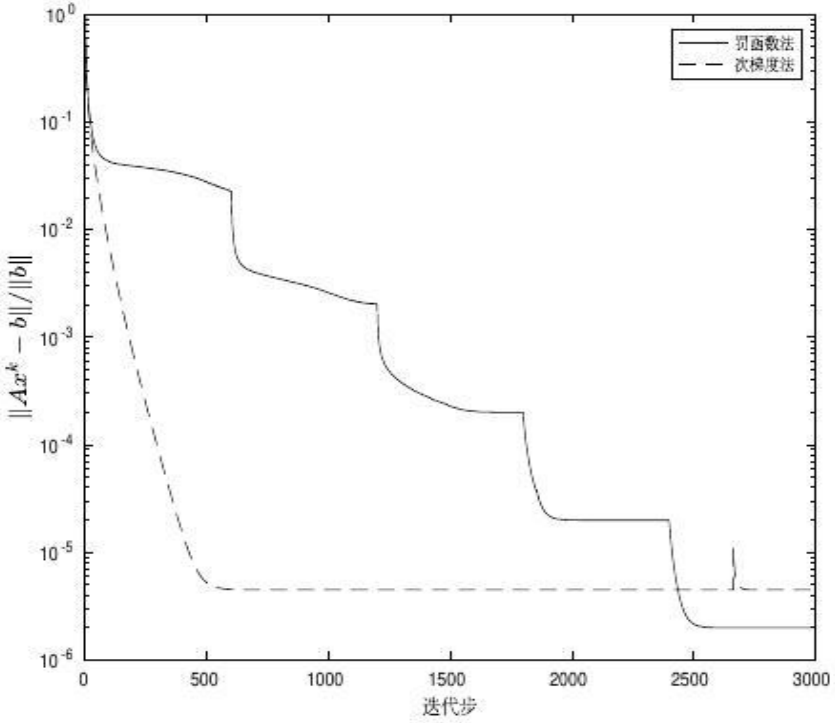


Figure: (b) 约束违反度变化趋势

口 内点罚函数法

内点罚函数在迭代时始终要求自变量x不能违反约束，故主要用于不等式约束优化问题。对于不等式优化问题，定义对数罚函数：

$$P_I(x,\sigma) = f(x) - \sigma \sum_{i \in \mathrm{I}} \ln(-c_i(x))$$

其中等式右端第二项称为惩罚项，$\sigma > 0$ 称为罚因子.

- $\mathrm{P}_I(\mathrm{x}, \sigma)$ 的定义为域 $\{ x | c_i(x) < 0 \}$ 因此在迭代过程中自变量 x 严格位于可行域内部.
- 当 x 趋于可行域边界时，由于对数罚函数的特点，$\mathrm{P}_I(\mathrm{x}, \sigma)$会趋于正无穷，这说明对数罚函数的极小值严格位于可行域内部．但原问题最优解通常位 于可行域边界，应减小惩罚效果，即调整罚因子 σ 使其趋于0.

例3

考虑优化问题

$$\begin{aligned} \min \quad & x^2+2xy+y^2+2x-2y \\ \text{s.t.} \quad & x \geqslant 0,\ y \geqslant 0 \end{aligned}$$

容易求得最优解为$x=0,\ y=1$，考虑对数罚函数

$$P_I(x,y,\sigma)=x^2+2xy+y^2+2x-2y-\sigma(\ln x+\ln y)$$

- $P_I(x,\sigma)$ 的定义为域 $\{x|\ c_i(x)<0\}$ 因此在迭代过程中自变量 x 严格位于可行域内部.
- 当 x 趋于可行域边界时，由于对数罚函数的特点，$P_I(x,\sigma)$会趋于正无穷，这说明对数罚函数的极小值严格位于可行域内部．但原问题最优解通常位 于可行域边界，应减小惩罚效果，即调整罚因子 σ 使其趋于0.

对数罚函数法算法

Algorithm 11 对数罚函数法

1: 给定 $\sigma_0 > 0$，可行解 x^0，$k \leftarrow 0$．罚因子缩小系数 $\rho \in (0,1)$．
2: **while** 未达到收敛准则 **do**
3: 以 x^k 为初始点，求解 $x^{k+1} = \arg\min_x P_I(x, \sigma_k)$
4: 选取 $\sigma_{k+1} = \rho\sigma_k$．
5: $k \leftarrow k+1$．
6: **end while**

- 初始点x_0 必须是一个可行点，常用的收敛准则可以包含

$$\left|\sigma_k \sum_{i\in \mathrm{I}} \ln(-c_i(x^{k+1}))\right| \leq \varepsilon.$$

- 当 σ 趋于 0 的时候，同样存在数值困难

口 精确罚函数法

- 由于二次罚函数存在数值困难，并且与原问题的解存在误差，故考虑精确罚函数.
- **精确罚函数**，是一种问题求解时不需要令罚因子趋于正无穷（或零）的罚函数. 常用的精确罚函数是ℓ_1 罚函数.

定义 (一般约束优化问题的ℓ_1罚函数)

$$P(x,\sigma) = f(x) + \sigma\left[\sum_{i\in \mathrm{E}} |c_i(x)| + \sum_{i\in \mathrm{I}} \tilde{c}_i(x)\right]$$

这里用绝对值代替二次惩罚项，下面的定理揭示了ℓ_1 罚函数的精确性

ℓ_1精确罚函数法

引理 (1)

若 $c_i(x^*) \leq 0 (i \in \mathrm{I})$, $c_i(x^*) = 0 (i \in \mathcal{E})$, $I = \{i \mid c_i(x^*) = 0, i \in \mathrm{I}\}$, 并且 $c_i(x)$ 在 x^* 处是连续可微的, 则存在 ϵ, 使得下列结论等价:

(1) 不存在 $u_i, i \in I, v_i, i \in \mathcal{E}$ 使得下列式子成立(其中 u_i, v_i 均不为0)

$$\sum_{i \in I} u_i \nabla c_i(x^*) + \sum_{i \in \mathrm{E}} v_i \nabla c_i(x^*) = 0, u_i \geq 0, i \in I$$

(2) 存在 ϵ, 对任意有界函数 $b(x) : N(x^*; \epsilon) \rightarrow \mathrm{R}^k$, 均存在有界函数 $d(x) : N(x^*; \epsilon) \rightarrow \mathrm{R}^n$, 使得任意 $x \in N(x^*; \epsilon)$ 均有:

$$\nabla c_i(x)^T d(x) \leq -1, i \in \mathrm{I}, \quad \nabla c_i(x)^T d(x) = b_i(x), \ i \in \mathrm{E}$$

其中 k 为等式约束的个数，n 为变量个数

□ ℓ_1精确罚函数法

引理 (2)

$c_i(x)(i \in \mathcal{E} \cup \mathrm{I})$ 在 x^* 处的邻域处是连续可微的, 并且 x^* 是原问题的严格极小值点, 则存在 $\bar{\sigma}$, 使得对任意$\sigma > \bar{\sigma}$, 均存在正数 $\epsilon(\sigma)$, 和一个向量 $x(\sigma) \in \mathrm{R}^n$ 满足:

$$(i)\ x(\sigma) \in N\left(x^*; \grave{o}(\sigma)\right)$$

$$(ii)\ \lim_{\sigma \to \infty} \grave{o}(\sigma) = 0$$

$$(iii)\ P\left(x(\sigma), \sigma\right) \leq P(x, \sigma),\ \forall x \in N\left(x^*; \grave{o}(\sigma)\right)$$

ℓ_1精确罚函数法

定理 (精确罚函数法的收敛性 1)

设 x^* 是原问题的一个严格局部极小解，$c_i(x)(i \in \mathcal{E} \cup \mathrm{I})$ 在 x^* 处的邻域处是可微的，并且引理74 中的 (1) 成立, 则当罚因子 σ 足够大时，x^* 也为 $P(x, \sigma)$的一个局部极小解（只要罚因子充分大，原问题的极小值点就是ℓ_1罚函数的极小值点）

定理 (精确罚函数法的收敛性 2)

设 x^* 是一般约束优化问题的一个严格局部极小解，且满足 KKT 条件，其对应的拉格朗日乘子为 $\lambda_i^*, i \in \mathcal{E} \cup \mathrm{I}$，则当罚因子 $\sigma > \sigma^*$ 时，x^* 也为 $P(x, \sigma)$ 的一个局部极小解，其中

$$\sigma^* = \| \lambda^* \|_\infty \overset{\text{def}}{=} \max_i | \lambda_i^* |$$

ℓ_1精确罚函数法

Proof. 设 x^* 是原问题在 $N(x^*, \bar{\epsilon})$ 的极小值, 如果 $I=\{i \mid c_i(x^*)=0, i \in \mathrm{I}\}$ 为空集, 并且没有等式约束，则此时结论明显成立. 故假设 I 不为空集或者至少有一个等式约束, 由引理75, 对于足够大的 σ, 存在 $\epsilon(\sigma)>0$ 并且 $x(\sigma)$ 满足 $x(\sigma)$在 $N(x^*; \epsilon(\sigma))$ 是 $P_1(x, \sigma)$ 的最小值. 并且 $\lim_{\sigma\to\infty}\epsilon(\sigma)=0$. 令 σ 充分大并且 满足 $\epsilon(\sigma) \leq \epsilon$, 此时若 $x(\sigma)$ 是可行点, 则由引理75 可知:

$$f(x^*)=P_1(x^*, \sigma) \geq P(x(\sigma), \sigma)=f(x(\sigma))$$

再由x^*的定义可知 $x^*=x(\sigma)$, 则此时结论得证. 所以我们只需要证明对足够大的 σ,$x(\sigma)$ 是可行点. 利用反证法：下假设存在一列 σ_i 使得 $x(\sigma_i)$ 不为原问题的可行解，则定义 $b(x)$ 如下:

$$b_i(x)=\begin{cases}-c_i(x)/\mid c_i(x)\mid & \text{if } c_i(x)\neq 0, i\in \mathrm{E}\\ 0 & \text{if } h_i(x)=0, i\in \mathrm{E}\end{cases}$$

□ ℓ_1精确罚函数法

Proof. 由引理74 可知存在有界函数$d(x)$满足

$$\nabla c_i(x)^T d(x) \le -1, \quad i \in I,$$

$$\nabla c_i(x)^T d(x) = \begin{cases} -1 & \text{if } c_i(x) > 0, i \in \mathrm{E} \\ 0 & \text{if } c_i(x) = 0, i \in \mathrm{E} \\ 1 & \text{if } c_i(x) < 0, i \in \mathrm{E} \end{cases}$$

则选择 $\epsilon_1 \in (0, \epsilon]$使得 $c_i(x) \in N(x^*; \epsilon_1)$并且 $i \notin \mathrm{I}$:

$$P'(x, \sigma, d(x)) = \nabla f(x)^T d(x) + \sigma \sum_{c_i(x)>0, i \in \mathrm{I}} \nabla c_i(x)^T d(x) + \sigma \sum_{c_i(x)=0, i \in \mathrm{I}} \nabla c_i(x)^T d(x)$$

$$+\sigma \sum_{c_i(x)=0, i \in \mathrm{I}} |\nabla c_i(x)^T d(x)| - \sigma \sum_{i \in \mathrm{E}} |\nabla c_i(x)^T d(x)| \le \nabla f(x)^T d(x) - \sigma$$

σ 足够大时 $d(x)$ 为下降方向，这与 x^* 为原问题的局部极小值点矛盾.

精确罚函数法算法

Algorithm 12 精确罚函数法

1: 给定 $\sigma_1 > 0, x_0, k \leftarrow 1$. 罚因子增长系数 $\rho > 1$.
2: **while** 未达到收敛准则 **do**
3: 以 x^k 为初始点，求解
$$x^{k+1} = \arg\min_x \left\{ f(x) + \sigma \left[\sum_{i\in\mathcal{E}} |c_i(x)| + \sum_{i\in\mathcal{I}} \tilde{c}_i(x) \right] \right\}$$
4: 选取 $\sigma^{k+1} = \rho\sigma_k$.
5: $k \leftarrow k + 1$
6: **end while**

- 取 ρ 为固定值是一种在实际中行之有效的方法，然而也可能出现：
  - 罚因子过大时子问题求解困难，此时需要适当减小罚因子
  - 初始罚因子过小，迭代次数增加，且最优解可能远离原问题最优解
- 子问题求解的初始点取法不唯一。一般取上一次子问题求解的最优值点作为下一次子问题求解的起点。

精确罚函数法的非光滑性

下面说明，精确罚函数必然是非光滑的。

为简化讨论，假设仅有一条等式约束 $c_1(x)=0$。设罚函数的形式为：

$$P(x,\sigma)=f(x)+\sigma h(c_1(x))$$

其中，函数 $h:\mathrm{R}\to\mathrm{R}$ 满足 $h(y)\geq 0,\ \forall y\in\mathrm{R}$ 且 $h(0)=0.$

若函数 h 连续可微，则有 $\nabla h(0)=0$ 成立。故对于 $P(x,\sigma)$ 最优点 x^*，有

$$0=\nabla P(x^*,\sigma)=\nabla f(x^*)+\sigma\nabla c_1(x^*)\ \nabla h(c_1(x^*))=\nabla f(x^*)$$

然而，在约束优化问题中，f 取到最小值时，其梯度不一定为 0。这说明假设 h 连续可微是不正确的，即罚函数项必须是非光滑的。

另一方面，正是罚函数项的非光滑性，克服了原函数在最优点处的梯度，才能因子下实现精确求解。

二次罚函数法的数值困难

对于等式约束问题:

$$\min_x \quad f(x)$$
$$s.t. \quad c_i(x)=0, \qquad \forall i \in \varepsilon. \tag{74}$$

二次罚函数法需要求解最小化罚函数的子问题:

$$\min \quad P_E(x,\sigma)=f(x)+\frac{1}{2}\sigma\sum_{i\in \mathrm{E}} c_i^2(x)$$

由$c_i(x^{k+1})\approx-\frac{\lambda_i^*}{\sigma_k}$,为了满足可行性条件, 必须使 σ_k 趋于 ∞, 这造成了子问题求解的数值困难.

接下来介绍的增广拉格朗日函数法可以利用有限的罚因子逼近最优解, 从而避免了上述必须使罚因子迅速膨胀的数值困难.

等式约束问题的增广拉格朗日函数法

定义 (等式约束问题的增广拉格朗日函数)

对于等式约束问题(74), 定义**增广拉格朗日函数**为:

$$L_\sigma(x,\lambda)=f(x)+\sum_{i\in \mathrm{E}}\lambda_i c_i(x)+\frac{1}{2}\sigma\sum_{i\in \mathrm{E}}c_i^2(x).$$

这即是在拉格朗日函数的基础上添加等式约束的二次罚函数.

由定义可得, 在第 k 步迭代, 给定罚因子 σ_k 和乘子 λ^k, $L_{\sigma_k}(x,\lambda^{k+1})$的最小值点$x^{k+1}$应满足梯度条件

$$\nabla_x L_{\sigma_k}\left(x^{k+1},\lambda^k\right)=\nabla f\left(x^{k+1}\right)+\sum_{i\in \mathrm{E}}\left(\lambda_i^k+\sigma_k c_i\left(x^{k+1}\right)\right)\nabla c_i\left(x^{k+1}\right)=0. \quad (75)$$

□ 等式约束问题的增广拉格朗日函数法

将(75) 式对比优化问题(74) 满足的 KKT 条件 (对最优解 (x^*,λ^*) 的梯度条件)

$$\nabla f(x)+\sum_{i\in \mathrm{E}}\lambda_i^*\nabla c_i(x)=0 \qquad (76)$$

$$\lambda_i^* \approx \lambda_i^k+\sigma_k c_i\left(x^{k+1}\right), \quad \forall i\in \mathrm{E}, \qquad (77)$$

为保证(75) 和(76) 式在最优解处的一致性, 对充分大的 k, 应满足:

即等价于

$$c_i\left(x^{k+1}\right)\approx\frac{1}{\sigma_k}\left(\lambda_i^*-\lambda_i^k\right).$$

约束优化算法

由此得出希望设计的增广拉格朗日算法具有如下的特性.

- 增广拉格朗日函数法通过合理更新乘子, 即通过控制 $\lambda_i* - \lambda^k$ 降低约束违反度.
- 因为根据约束违反度满足的公式, 当 λ_i^k 足够接近 λ_i* 时, $c_i(x^{k+1})$ 将远小于 $1/\sigma_k$.

(77) 式的一个截断近似可以写为:

$$\lambda_i^* = \lambda_i^k + \sigma_k c_i\left(x^{k+1}\right), \quad \forall i \in \mathrm{E},$$

这可以作为算法中乘子的更新方式.

根据如上讨论, 并对 $c(x)$, $\nabla c(x)$ 沿用罚函数法的定义, 我们将在下文写出等式约束问题增广拉格朗日函数法的具体算法.

口 等式约束问题的增广拉格朗日函数法

算法 13 增广拉格朗日函数法

Input: $x^0 \in \mathbb{R}^n$, λ^0, $\sigma_0 > 0$, $\varepsilon > 0$, 精度 $\eta_k > 0$, 迭代步 $k = 0$.

Output: x^{k+1}, λ^k.

检查初始元素.

for $k = 0, 1, 2, \cdots$ do **do**

以 x^k 为初始点，求解 $\min_x \quad L_{\sigma_k}\left(x, \lambda^k\right)$，得到满足需求的精度条件 $\left\|\nabla_x L_{\sigma_k}\left(x, \lambda^k\right)\right\| \leqslant \eta_k$ 的解 x^{k+1}.

if $\left\|c\left(x^{k+1}\right)\right\| \leqslant \varepsilon$ **then**

返回近似解 $\left(x^{k+1}, \lambda_k\right)$，终止迭代.

end if

更新乘子: $\lambda^{k+1} = \lambda^k + \sigma_k c\left(x^{k+1}\right)$.

更新罚因子: $\sigma_{k+1} = \rho\sigma_k$.

end for

使用增广拉格朗日函数法的实例

为了直观理解罚函数的作用，我们给出一个例子:
考虑优化问题

$$\begin{aligned} \min \quad & x+\sqrt{3}y \\ \text{s.t.} \quad & x^2+y^2=1 \end{aligned}$$

容易求得最优解为 $\left(-\frac{1}{2}, -\frac{\sqrt{3}}{2}\right)$, 相应的拉格朗日乘子 $\lambda^*=1$.

根据增广拉格朗日函数的形式, 写出本问题的增广拉格朗日函数:

$$L_\sigma(x,y,\lambda)=x+\sqrt{3}y+\lambda\left(x^2+y^2-1\right)+\frac{\sigma}{2}\left(x^2+y^2-1\right)^2$$

并在下图中绘制出 $L_2(x, y, 0.9)$对应的等高线.

口 二次罚函数法与增广拉格朗日函数法求解的等高线

图中标“*”的点为原问题的最优解 x^*
标“∘”的点为罚函数或增广拉格朗日函数的最优解

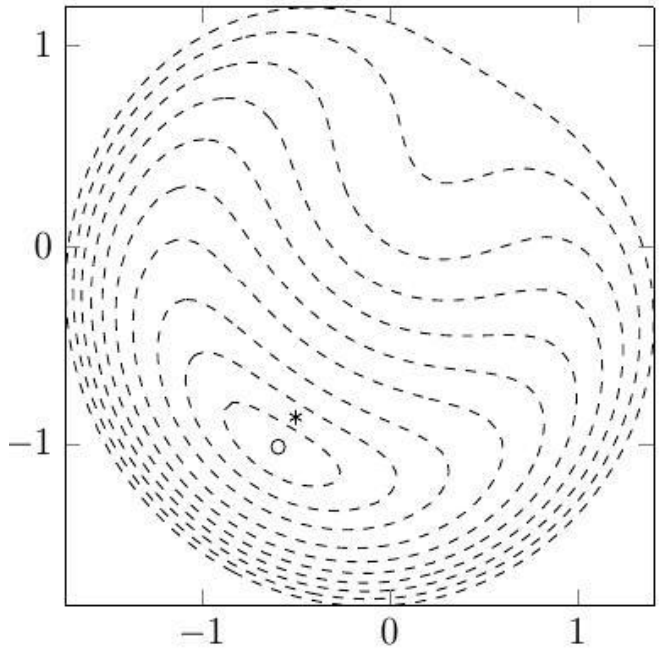


Figure: (a) 二次罚函数

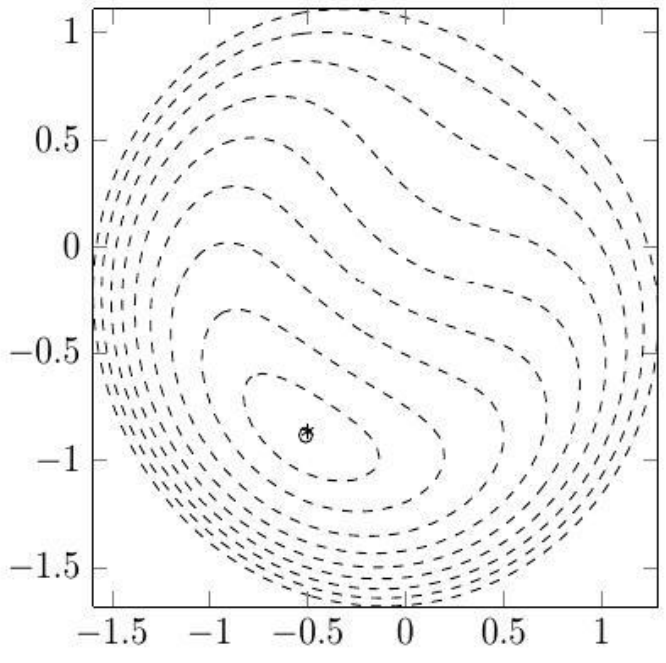


Figure: (b) 增广拉格朗日函数

口 比较与结论

比较二次罚函数和增广拉格朗日函数在最优解探寻方面的有效性.

- 二次罚函数法求出的最优解为 (0.5957, 1.0319), 与最优解的欧氏距离约0.1915, 约束违反度为 0.4197.
- 增广拉格朗日罚函数法求出的最优解为 (0.5100, 0.8833), 与最 优解的欧氏距离约 0.02, 约束违反度为 0.0403.
- 增广拉格朗日函数法可具有比二次罚函数法更精确的寻优能力, 且约束违反度一般更低.
- σ^k与σ^{k+1} 接近时, x^k 可以作为求解 x^{k+1}的初始点, 以加快收敛.

在实际中, 应该控制 σ^k 的增长维持在一个合理的速度区间内. 一个简单的方法是维持 $\rho \in [2, 10]$, 不过近年来也有学者设计了更合理的自适应方法.

口 收敛性分析

阐述由增广拉格朗日函数法导出的极小值点和原问题的极小值点有什么关系.
实际上, 增广拉格朗日函数在一定条件下将成为精确罚函数.

定理

严格局部极小解定理

设x^*, λ^* 分别为问题(74) 的局部极小解和相应的乘子, 且点x^*处$LICQ$ 和二阶充分条件成立. 则:
存在有限的常数$\bar{\sigma}$, 对任意的$\sigma \geqslant \bar{\sigma}$, x^* 都是$L_\sigma(x, \lambda^*)$ 的严格局部极小解.
反之, 若x^* 为$L_\sigma(x, \lambda^*)$的局部极小解且满足$c_i(x^*) = 0,\ i \in E$, 则x^*为问题(74) 的局部极小解.

口 定理证明

因为x^*为问题(1) 的局部极小解且二阶充分条件成立, 所以

$$\begin{aligned}\nabla_x L(x^*,\lambda^*)&=\nabla f(x^*)+\sum_{i\in \mathrm{E}}\lambda_i^*\nabla c_i(x^*)=0,\\ u^T\nabla_{xx}^2 L(x^*,\lambda^*)u&>0,\\ \nabla c(x^*)^T u&=0,\quad \forall u.\end{aligned}\tag{78}$$

对比$L_\sigma(x^*, \lambda^*)$和$L(x^*, \lambda^*)$的表达式, 由$c_i(x^*)=0,\ i\in E$, 得

$$\begin{aligned}\nabla_x L_\sigma(x^*,\lambda^*)&=\nabla_x L(x^*,\lambda^*)=0,\\ \nabla_{xx}^2 L_\sigma(x^*,\lambda^*)&=\nabla_{xx}^2 L(x^*,\lambda^*)+\sigma\nabla c(x^*)\nabla c(x^*)\end{aligned}\tag{79}$$

为了证明x^*是$L_\sigma(x^*, \lambda^*)$的严格局部极小解, 只需证对于充分大的σ 成立

$$\nabla_{xx}^2 L_\sigma(x^*,\lambda^*)\succ 0.$$

口 定理证明

假设该结论不成立, 则对任意大的σ, 存在u_k 满足$\|u_k\|=1$, 且满足

$$u_k^T\nabla_{xx}^2 L_\sigma(x^*,\lambda^*)u_k = u_k^T\nabla_{xx}^2 L(x^*,\lambda^*)u_k + \sigma\left\|\nabla c(x^*)^T u_k\right\|^2 \le 0,$$

则

$$\left\|\nabla c(x^*)^T u_k\right\|^2 \le -\frac{1}{\sigma}u_k^T\nabla_{xx}^2 L(x^*,\lambda^*)u_k \to 0, \quad \sigma\to\infty.$$

因为 $\{u_k\}$ 为有界序列, 必存在聚点, 设为 u. 那么

$$\nabla c\left(x^*\right)^{\mathrm{T}} u=0, \quad u^{\mathrm{T}}\nabla_{xx}^2 L\left(x^*,\lambda^*\right)u\le 0.$$

这与(78) 式矛盾, 故结论成立.

反之, 若 x^*满足 $c_i(x^*)=0,\ i\in E$且为 $L_\sigma(x,\lambda^*)$的局部极小解, 那么对于任意与 x^* 充分接近的可行点 x, 我们有

$$f(x^*)=L_\sigma(x^*,\lambda^*)\le L_\sigma(x,\lambda^*)=f(x).$$

口 收敛性分析

对于增广拉格朗日方法，通过进一步假设乘子点列的有界性和收敛点处的约束品性，算法迭代生成的序列 $\{x^k\}$ 会有子列收敛至问题(74) 的一阶稳定点.

定理

增广拉格朗日函数法的收敛性

假设乘子列 $\{\lambda_k\}$是有界的，罚因子$\sigma_k \to \infty$, $k \to \infty$, ，上述增广拉格朗日方法中精度 $\mu_k \to 0$, 迭代点列 $\{x^k\}$ 的一个子序列 $\{x^{k_j+1}\}$ 收敛到 x^*，并且在点 x^*LICQ 成立.

那么存在 λ^*，满足:

$$\lambda^{k_j+1} \to \lambda^*, \quad j \to \infty,$$

$$\nabla f(x^*) + \nabla c(x^*)\lambda^* = 0, \quad c(x^*) = 0.$$

定理证明

对于增广拉格朗日函数$L_{\sigma_k}(x^*, \lambda^k)$

$$\nabla_x L_{\sigma_k}\left(x^{k+1}, \lambda^k\right) = \nabla f\left(x^{k+1}\right) + \nabla c\left(x^{k+1}\right)\left(\lambda^k + \sigma_k c\left(x^{k+1}\right)\right)$$

$$= \nabla f\left(x^{k+1}\right) + \nabla c\left(x^{k+1}\right)\lambda^{k+1} = \nabla_x L\left(x^{k+1}, \lambda^{k+1}\right).$$

由于点 x^* 处 *LICQ* 成立, 故 $rank(\nabla c(x^{k_j+1}))= |\varepsilon|$成立， （当 x^{k_j+1}充分接近x^* 时），从而下式成立：

$$\lambda^{k_j+1} = \left(\nabla c\left(x^{k_j+1}\right)^{\mathrm{T}} \nabla c\left(x^{k_j+1}\right)\right)^{-1} \nabla c\left(x^{k_j+1}\right)^{\mathrm{T}} \left(\nabla_x L_{\sigma_k}\left(x^{k_j+1}, \lambda^{k_j}\right) - \nabla f\left(x^{k_j+1}\right)\right).$$

因为$\left\|\nabla_x L_{\sigma_k}(x^{k_j+1}, \lambda^{k_j})\right\| \le \eta_{k_j} \to 0$，我们有

$$\lambda^{k_j+1} \to \lambda^* \overset{\text{def}}{=} -\left(\nabla c\left(x^*\right)^{\mathrm{T}} \nabla c\left(x^*\right)\right)^{-1} \nabla c\left(x^*\right)^{\mathrm{T}} \nabla f\left(x^*\right),$$

$$\nabla_x L\left(x^*, \lambda^*\right) = 0.$$

而乘子列$\{\lambda_k\}$是有界的, 且$\lambda^{k_j} + \sigma_{k_j} c(x^{k_j+1}) \to \lambda^*$, 故$\{\sigma_{k_j} c(x^{k_j+1})\}$有界. 又$\sigma_k \to +\infty$, 则 $c(x^*) = 0.$

口 收敛性分析

定理

增广拉格朗日函数法的收敛性 (基于更弱的假设)

假设 x^*, λ^* 分别是问题 (74) 的严格局部极小解和相应的乘子, 则存在充分大的常数 $\bar{\sigma} > 0$ 和充分小的常数 $\delta > 0$, 如果对某个 k, 有

$$\frac{1}{\sigma_k}\left\|\lambda^k - \lambda^*\right\| < \delta, \quad \sigma_k \geq \bar{\sigma}$$

则

$$\lambda^k \to \lambda^*, \quad x^k \to x^*.$$

同时, 如果

(1) $\limsup \sigma_k < +\infty$ 且 $\lambda^k \neq \lambda^*, \forall k$, 则 $\{\lambda^k\}$收敛的速度是 Q-线性;

(2) $\limsup \sigma_k = +\infty$ 且 $\lambda^k \neq \lambda^*, \forall k$, 则 $\{\lambda^k\}$收敛的速度是 Q-超线性.

一般约束问题的增广拉格朗日函数法

考虑一般约束问题：

$$\begin{aligned} &\min_{x} \quad f(x) \\ &s.t. \ \ c_i(x)=0, \qquad \forall i \in \varepsilon. \\ &\qquad c_i(x) \le 0, \qquad \forall i \in \mathrm{I}. \end{aligned} \tag{80}$$

对于问题(80)，一般引入松弛变量，得到如下等价形式：

$$\begin{aligned} &\min_{x} \quad f(x) \\ &s.t. \ \ c_i(x)=0, \qquad \forall i \in \varepsilon. \\ &\qquad c_i(x)+s_i=0, \qquad \forall i \in \mathrm{I}. \\ &\qquad s_i \ge 0, \qquad \forall i \in \mathrm{I}. \end{aligned} \tag{81}$$

构造增广拉格朗日函数

保留非负约束, 可以构造拉格朗日函数

$$L(x,s,\lambda,\mu)=f(x)+\sum_{i\in \mathrm{E}}\lambda_i c_i(x)+\sum_{i\in \mathrm{I}}\mu_i\left(c_i(x)+s_i\right),\quad s_i\geq 0,\quad i\in \mathrm{I}$$

记问题(81) 中等式约束的二次罚函数为$p(x, s)$, 即

$$p(x,s)=\sum_{i\in \mathrm{E}}c_i^2(x)+\sum_{i\in \mathrm{I}}\left(c_i(x)+s_i\right)^2,$$

那么可以同样构造增广拉格朗日函数如下:

$$L_\sigma(x,s,\lambda,\mu)=f(x)+\sum_{i\in \mathrm{E}}\lambda_i c_i(x)+\sum_{i\in \mathrm{I}}\mu_i\left(c_i(x)+s_i\right)+\frac{\sigma}{2}p(x,s),\quad s_i\geq 0,\quad i\in \mathrm{I}.$$

消元法求解子问题

在第 k 步迭代中, 给定乘子 λ^k, μ^k 和罚因子问题:

$$\min_{x,s} \quad L_{\sigma_k}\left(x,s,\lambda^k,\mu^k\right), \quad \text{s.t.} \quad s\geq 0, \tag{82}$$

以得到x^{k+1}, s^{k+1}.

现在介绍一种基于消元的方法, 即考虑消去s, 求解只关于x 的优化问题.

首先固定x, 关于s 的子问题化为

$$\min_{s\geq 0}\sum_{i\in \mathrm{I}}\mu_i\left(c_i(x)+s_i\right)+\frac{\sigma_k}{2}\sum_{i\in \mathrm{I}}\left(c_i(x)+s_i\right)^2.$$

容易直接解得使子问题最优且满足非负约束的 s_i 为

$$s_i=\max\left\{-\frac{\mu_i}{\sigma_k}-c_i(x),0\right\}, \quad i\in \mathrm{I}.$$

消元法求解子问题

将 s_i 的表达式代入 L_{σ_k} 我们有

$$L_{\sigma_k}(x,\lambda^k,\mu^k)=f(x)+\sum_{i\in \mathrm{E}}\lambda_i c_i(x)+\frac{\sigma_k}{2}\sum_{i\in \mathrm{E}}c_i^2(x)+\frac{\sigma_k}{2}\sum_{i\in \mathrm{I}}\left(\max\left\{\frac{\mu_i}{\sigma_k}+c_i(x),0\right\}^2-\frac{\mu_i^2}{\sigma_k^2}\right).$$

其为关于x 的连续可微函数(假设$f(x),\quad c_i(x),\quad i\in \mathrm{I}\cup \mathrm{E}$ 连续可微). 因此, 问题(82) 等价于

$$\min_{x\in\mathbb{R}^n}\quad L_{\sigma_k}\left(x,\lambda^k,\mu^k\right).$$

并可以利用梯度法进行求解.

注意: 这里, 我们消去了变量 s, 因此可以只考虑关于 x 的优化问题.

更新乘子

对于问题(81), 其最优解x^*, s^* 和乘子λ^*, μ^* 需满足KKT 条件:

$$0=\nabla f(x^*)+\sum_{i\in \mathrm{E}}\lambda_i^*\nabla c_i(x^*)+\sum_{i\in \mathrm{I}}\mu_i^*\nabla c_i(x^*),\quad \mu_i^*\geq 0,\quad s_i^*\geq 0,\quad i\in \mathrm{I}$$

问题(82) 的最优解 x^{k+1}, s^{k+1} 满足

$$0=\nabla f\left(x^{k+1}\right)+\sum_{i\in \mathrm{E}}\left(\lambda_i^k+\sigma_k c_i\left(x^{k+1}\right)\right)\nabla c_i\left(x^{k+1}\right)+\sum_{i\in \mathrm{I}}\left(\mu_i^k+\sigma_k\left(c_i\left(x^{k+1}\right)+s_i^{k+1}\right)\right)\nabla c_i\left(x^{k+1}\right)$$

$$s_i^{k+1}=\max\left\{-\frac{\mu_i^k}{\sigma_i^k}-c_i\left(x^{k+1}\right),0\right\},\quad i\in \mathrm{I}.$$

对比问题(81) 和问题(82) 的KKT 条件, 易知乘子的更新格式为

$$\lambda_i^{k+1}=\lambda_i^k+\sigma_k c_i\left(x^{k+1}\right),\quad i\in \mathrm{E},\quad \mu_i^{k+1}=\max\left\{\mu_i^k+\sigma_k c_i\left(x^{k+1}\right),0\right\},\quad i\in \mathrm{I}.$$

口 收敛性分析

定理

增广拉格朗日函数法的收敛性 (基于更弱的假设)

假设 x^*, λ^* 分别是问题 (74) 的严格局部极小解和相应的乘子, 则存在充分大的常数 $\bar{\sigma} > 0$ 和充分小的常数 $\delta > 0$, 如果对某个 k, 有

$$\frac{1}{\sigma_k}\left\|\lambda^k - \lambda^*\right\| < \delta, \quad \sigma_k \geq \bar{\sigma}$$

则

$$\lambda^k \to \lambda^*, \quad x^k \to x^*.$$

同时, 如果

(1) $\limsup \sigma_k < +\infty$ 且 $\lambda^k \neq \lambda^*, \forall k$, 则 $\{\lambda^k\}$收敛的速度是 Q-线性;

(2) $\limsup \sigma_k = +\infty$ 且 $\lambda^k \neq \lambda^*, \forall k$, 则 $\{\lambda^k\}$收敛的速度是 Q-超线性.

约束违反度与参数更新

对于等式约束, 我们定义约束违反度为

$$v_k\left(x^{k+1}\right)=\sqrt{\sum_{i\in \mathrm{E}} c_i^2\left(x^{k+1}\right)+\sum_{i\in \mathrm{I}}\left(c_i\left(x^{k+1}\right)+s_i^{k+1}\right)^2}.$$

根据 (83) 式消去 s, 得

$$v_k\left(x^{k+1}\right)=\sqrt{\sum_{i\in \mathrm{E}} c_i^2\left(x^{k+1}\right)+\sum_{i\in \mathrm{I}} \max\left\{c_i\left(x^{k+1}\right),-\frac{\mu_i^k}{\sigma_k}\right\}^2}.$$

在算法中, 需要根据约束违反度的大小判断参数的更新方式:

- 若$v_k(x^{k+1})$满足精度条件, 则进行乘子的更新, 并提高子问题求解精度, 罚因子不变;
- 若不满足, 则不进行乘子的更新, 并适当增大罚因子以便得到约束违反度更小的解.

口 一般约束增广拉格朗日函数法算法

- 选取初始点 x^0, 乘子 λ^0, μ^0, 罚因子 $\sigma_0 > 0$, 约束违反度常数 $\varepsilon > 0$, 精度常数 $\eta > 0$, 以及常 数 $0 < \alpha \leqslant \beta \leqslant 1$ 和 $\rho > 1$. 今 $\eta_0 = \frac{1}{\sigma_0}, \varepsilon_0 = \frac{1}{\sigma_0^{\alpha}}$, 以 及 $k = 0$.
- **for** $k = 0, 1, 2, \ldots$ **Do**
  以 x^k 为初始点, 求解 $\min\limits_{x} L_{\sigma_k}\left(x, \lambda^k, \mu^k\right)$,
  得到满足精度条件 $\left\|L_{\sigma_k}\left(x^{k+1}, \lambda^k, \mu^k\right)\right\|_2 \leq \eta_k$ 的解 x^{k+1}.
- **If** $v_k(x^{k+1}) \leqslant \varepsilon_k$ **then**
  If $v_k(x^{k+1}) \leqslant \varepsilon_k$ 且 $\left\|\nabla_x L_{\sigma_k}\left(x^{k+1}, \lambda^k, \mu^k\right)\right\|_2 \leq \eta$ **then**
  得到逼近解 $x^{k+1}, \lambda^k, \mu^k$, 终止迭代.
  end if

一般约束增广拉格朗日函数法算法(续)

- 更新乘子: $\lambda_i^{k+1} = \lambda_i^k + \sigma_k c_i\left(x^{k+1}\right), \quad i \in \mathrm{E}, \qquad \mu_i^{k+1} = \max\left\{\mu_i^k + \sigma_k c_i\left(x^{k+1}\right), 0\right\}, \quad i \in \mathrm{I}.$

- 罚因子不变: $\sigma_{k+1} = \sigma_k$.

- **减小子问题求解误差和约束违反度:** $\eta_{k+1} = \dfrac{\eta_k}{\sigma_{k+1}}, \quad \varepsilon_{k+1} = \dfrac{\varepsilon_k}{\sigma_{k+1}^{\beta}}.$
- **else (注: 约束违反度不满足精度条件)**
- **乘子不变:** $\lambda^{k+1} = \lambda^k$.

  更新罚因子:$\sigma_{k+1} = \rho\sigma_k$.

  调整子问题求解误差和约束违反度: $\eta_{k+1} = \dfrac{1}{\sigma_{k+1}}, \quad \varepsilon_{k+1} = \dfrac{\varepsilon_k}{\sigma_{k+1}^{\alpha}}.$

end if

End for

一般约束增广拉格朗日函数法算法(续)

- 更新乘子: $\lambda_i^{k+1} = \lambda_i^k + \sigma_k c_i\left(x^{k+1}\right), \quad i \in \mathrm{E}, \qquad \mu_i^{k+1} = \max\left\{\mu_i^k + \sigma_k c_i\left(x^{k+1}\right), 0\right\}, \quad i \in \mathrm{I}.$

- 罚因子不变: $\sigma_{k+1} = \sigma_k$.

- **减小子问题求解误差和约束违反度:** $\eta_{k+1} = \dfrac{\eta_k}{\sigma_{k+1}}, \quad \varepsilon_{k+1} = \dfrac{\varepsilon_k}{\sigma_{k+1}^{\beta}}.$
- **else (注: 约束违反度不满足精度条件)**
- **乘子不变:** $\lambda^{k+1} = \lambda^k$.

  更新罚因子:$\sigma_{k+1} = \rho\sigma_k$.

  调整子问题求解误差和约束违反度: $\eta_{k+1} = \dfrac{1}{\sigma_{k+1}}, \quad \varepsilon_{k+1} = \dfrac{\varepsilon_k}{\sigma_{k+1}^{\alpha}}.$

end if

End for

凸优化问题的增广拉格朗日函数法

考虑凸优化问题(不等式形式)

$$\min_{x\in\mathbb{R}^n} \ f(x),$$
$$s.t. \quad c_i(x) \rightleftharpoons 0, \quad i = 1,2,\cdots,m$$

根据定义,写出问题(85) 的增广拉格朗日函数:

$$L_\sigma(x,\lambda) = f(x) + \frac{\sigma}{2}\sum_{i=1}^{m}\left(\max\left\{\frac{\lambda_i}{\sigma}+c_i(x),0\right\}^2 - \frac{\lambda_i^2}{\sigma^2}\right).$$

给定一列单调递增的乘子$\sigma_k \uparrow \sigma_\infty$,以及初始乘子$\lambda^0$,结合(84)式,问题(85)的增广拉格朗日函数法为

$$\begin{cases} x_{k+1} \approx arg\min\limits_{x\in\mathbb{R}^n} L_{\sigma_k}(x,\lambda_k), \\ \lambda^{k+1} = max\left(0,\lambda^k + \sigma_k c(x^{k+1})\right). \end{cases}$$

□ 凸问题的增广拉格朗日函数法的收敛性

定理

凸问题的增广拉格朗日函数法的收敛性

假设$\{x^k\},\{\lambda^k\}$为问题(85) 通过(86) 式生成的序列, x^{k+1}满足不精确条件(87). 如果问题(85) 的 *Slater* 约束品性成立, 那么序列 $\{\lambda^k\}$是有界序列且收敛到 λ^∞ (λ^∞为对偶问题的一个最优解).

如果存在一个γ使得下水平集$\{x \in X \mid f(x) \leqslant \gamma\}$是非空有界的, 那么序列$\{x^k\}$也是有界的, 并且其所有的聚点都是问题(85) 的最优解.

基追踪问题(BP)

考虑一类简单 基追踪问题. 设$A \in \mathrm{R}^{m\times n}(m \leqslant n)$, $b \in \mathrm{R}^{m}$,$x \in \mathrm{R}^{n}$,

$$\min_{x\in\mathbb{R}^n} \|x\|_1, \quad \text{s.t. } Ax=b$$

考虑其对偶问题:

$$\min b^{\mathrm{T}}y, \quad \text{s.t.} \| A^{\mathrm{T}}y\|_\infty \leq 1, \quad y\in\mathbb{R}^m \qquad (91)$$

通过引入变量s, 对偶问题可以等价地写成

$$\min b^{\mathrm{T}}y, \quad \text{s.t. } A^{\mathrm{T}}y-s=0, \quad \| s\|_\infty \leq 1, \quad y\in\mathbb{R}^m, \quad s\in\mathbb{R}^n \qquad (92)$$

□ 原始问题的增广拉格朗日函数法

根据问题(90) 的形式, 引入罚因子σ 和乘子 λ, 其增广拉格朗日函数为

$$L_\sigma(x,\lambda)=\|x\|_1+\lambda^{\mathrm{T}}(Ax-b)+\frac{\sigma}{2}\|Ax-b\|_2^2 \qquad (93)$$

固定 σ, 第k 步迭代更新格式为

$$\begin{cases} x^{k+1}=\arg\min\limits_{x\in\mathbb{R}^n}\left\{\|x\|_1+\dfrac{\sigma}{2}\left\|Ax-b+\dfrac{\lambda^k}{\sigma}\right\|_2^2\right\}, \\ \lambda^{k+1}=\lambda^k+\sigma\left(Ax^{k+1}-b\right). \end{cases} \qquad (94)$$

设迭代初始点 $x^0=\lambda^0=0$, 考虑格式(94) 中的第一步, 并假设 x^{k+1} 为 $L_\sigma(x,\lambda^k)$ 的一个全局极小解, 则对 $L_\sigma(x,\lambda^k)$ 利用极小性条件得

$$0\in\partial\|x^{k+1}\|_1+\sigma A^{\mathrm{T}}\left(Ax^{k+1}-b+\frac{\lambda^k}{\sigma}\right).$$

因此成立 $-A^T\lambda^{k+1}\in\partial\|x^{k+1}\|_1$.

口 收敛性分析与引理1

对固定的二次罚项系数 σ = 1, 迭代格式 (95) 具有有限终止性. 这是一个很强的结论.

引理

设迭代序列 $\{x^k\}$, $\{\lambda^k\}$ 是算法 (94) 从初始点 $x^0 = \lambda^0 = 0$ 产生的序列, 则若

$$(a)\| Ax^k - b\|_2 \text{是单调下降的：} \quad \| Ax^{k+1} - b\|_2 \le \| Ax^k - b\|_2 . \qquad (95)$$

$$(b)\text{若存在}\tilde{x}\text{满足}A\tilde{x} = b, \quad \text{则}\frac{\sigma}{2}\| Ax^k - b\|_2^2 \le \frac{1}{k}\| \tilde{x}\|_1 . \qquad (96)$$

口 引理 1 的证明

(a) 由迭代格式(94) 的第一步,

$$\| x^{k+1}\|_1+(\lambda^k)^{\mathrm{T}}(Ax^{k+1}-b)+\frac{\sigma}{2}\| Ax^{k+1}-b\|_2^2\leq\| x^k\|_1+(\lambda^k)^{\mathrm{T}}(Ax^k-b)+\frac{\sigma}{2}\| Ax^k-b\|_2^2.$$

由于 $\| x\|_1$ 的凸性, 有

$$\| x^{k+1}\|_1\geq\| x^k\|_1+\langle -A^{\mathrm{T}}\lambda^k, x^{k+1}-x^k\rangle,$$

结合上面两式,

$$\| Ax^{k+1}-b\|_2\leq\| Ax^k-b\|_2.$$

至此, 引理中(a) 所述的结论证毕.

口 引理 1 的证明

(b) 由迭代格式(94) 的第二步,

$$A^{\mathrm{T}}\left(\lambda^{k+1}-\lambda^{k}\right)=\sigma A^{\mathrm{T}}\left(Ax^{k+1}-b\right), \qquad (97)$$

于是

$$\frac{\sigma}{2}\left\|Ax^{k+1}-b\right\|_2^2-\frac{\sigma}{2}\|Ax-b\|_2^2 \leq\left\langle A^{\mathrm{T}}(\lambda^{k+1}-\lambda^{k}),\, x^{k+1}-x\right\rangle$$

$$\left(\frac{\sigma}{2}\|Ax-b\|_2^2\text{的}x^{k+1}\text{的凸性及}(97)\text{式}\right)$$

$$=\left\langle A^{\mathrm{T}}\lambda^{k+1}, x^{k+1}-x\right\rangle-\left\langle A^{\mathrm{T}}\lambda^{k}, x^{k}-x\right\rangle-\left\langle A^{\mathrm{T}}\lambda^{k}, x^{k+1}-x^{k}\right\rangle$$

$$\leq\left\langle A^{\mathrm{T}}\lambda^{k+1}, x^{k+1}-x\right\rangle-\left\langle A^{\mathrm{T}}\lambda^{k}, x^{k}-x\right\rangle+\|x^{k+1}\|_1-\|x^{k}\|_1.$$

$$\left(\|x\|_1\text{点}x^{k}\text{的凸性}\right)$$

口 引理 1 的证明

(b) 进一步

$$\left(\frac{\sigma}{2}\| Ax^k - b\|_2^2 - \frac{\sigma}{2}\| Ax - b\|_2^2\right)$$

$$\leq \sum_{j=1}^{k}\left(\frac{\sigma}{2}\| Ax^j - b\|_2^2 - \frac{\sigma}{2}\| Ax - b\|_2^2\right) \quad \left(\| Ax^k - b\|_2 \text{ 的单调性}\right)$$

$$\leq \langle A^{\mathrm{T}}\lambda^k, x^k - x\rangle + \| x^k\|_1 - \langle A^{\mathrm{T}}\lambda^0, x^0 - x\rangle - \| x^0\|_1 \quad \left(\| x\|_1 \text{的凸性}\right)$$

$$\leq \| x\|_1$$

取 $x = \tilde{x}$, 我们即有

$$\frac{\sigma}{2}\left\|Ax^k - b\right\|_2^2 \leq \frac{1}{k}\|\tilde{x}\|_1$$

至此, 引理中 (b) 所述的结论证毕.

口 引理 1 的证明

(b) 进一步

$$\left(\frac{\sigma}{2}\| Ax^k - b\|_2^2 - \frac{\sigma}{2}\| Ax - b\|_2^2\right)$$

$$\leq \sum_{j=1}^{k}\left(\frac{\sigma}{2}\| Ax^j - b\|_2^2 - \frac{\sigma}{2}\| Ax - b\|_2^2\right) \quad \left(\| Ax^k - b\|_2 \text{ 的单调性}\right)$$

$$\leq \langle A^{\mathrm{T}}\lambda^k, x^k - x\rangle + \| x^k\|_1 - \langle A^{\mathrm{T}}\lambda^0, x^0 - x\rangle - \| x^0\|_1 \quad \left(\| x\|_1 \text{的凸性}\right)$$

$$\leq \| x\|_1$$

取 $x = \tilde{x}$, 我们即有

$$\frac{\sigma}{2}\left\|Ax^k - b\right\|_2^2 \leq \frac{1}{k}\|\tilde{x}\|_1$$

至此, 引理中 (b) 所述的结论证毕.

口 收敛性证明的引理 2

引理

假设问题(90) 的可行域非空, x^k 是由迭代格式(94) 得到的满足 Ax^k = b 的迭代点, 则 x^k是 BP 问题(90) 的一个解.

Proof 对任意 x, 由 // x //$_1$ 的凸性, 有

$$\begin{aligned} \| x^k\|_1 &\le \| x\|_1 - \langle x - x^k, -A^{\mathrm{T}}\lambda^k\rangle \\ &= \| x\|_1 + \langle Ax - Ax^k, \lambda^k\rangle \\ &= \| x\|_1 + \langle Ax - b, \lambda^k\rangle, \end{aligned}$$

因此, 对任意的满足$Ax = b$ 的 x, 都 有 // x^k //$_1 \leqslant$ // x //$_1$. 故 x^k是问题 (90) 的最优解.

基追踪问题的收敛性定理

定理

简单基追踪问题的收敛性定理

假设问题 (90) 的可行域非空, 迭代序列$\{x^k\},\{\lambda^k\}$是由迭代格式 (94) 从初始点 $x^0 = \lambda^0 = 0$ 产生的, 则存在正整数 K 使得任意的 $x^k, k \geqslant K$ 是问题(90)的解.

口 定理的证明

对指标集 {1, 2, · · · , n} 的任一划分 (I_+^j, I_-^j, E^j) ,令

$$U^j \overset{\text{def}}{=} U(I_+^j, I_-^j, E^j) = \left\{x \middle| \ x_i \geq 0, i \in I_+^j; x_i \leq 0, i \in I_-^j; x_i = 0, i \in E^j\right\}$$

$$H^j \overset{\text{def}}{=} \min_{x \in \mathbb{R}^n} \left\{\frac{1}{2}\| Ax - b\|_2^2 \mid x \in U^j\right\}.$$

对于迭代点λ^k, 定义指标集{1, 2, · · · , n} 的划分为 $(I_+^{j_k}, I_-^{j_k}, E^{j_k})$

$$I_+^{j_k} = \{i : (A^{\mathrm{T}}\lambda^k)_i = -1\}, I_-^{j_k} = \{i : (A^{\mathrm{T}}\lambda^k)_i = 1\},$$

$$E^{j_k} = \{i : (A^{\mathrm{T}}\lambda^k)_i \in (-1, 1)\}.$$

并由 $\cup^j$ 的定义和 $-A^T\lambda^k \in \partial\left\|x^k\right\|_1$知, $x^k \in U^{j_k}$. 因为问题(90) 的可行域非空, 故存在 $\tilde{x}$ 满足 $\|\mathrm{A}\tilde{x} - b\| = 0$.

由引理 1 的 (b), 对任意满足 $H^j > 0$ 的 j, 存在一个充分大的 K_j 使得

$$x^k \notin U^j, \quad \forall k \geqslant K_j.$$

口 定理的证明

因此, 我们取$K=\max_j\{K_j|H^j>0\}$, 即有$H^{k_j}=0$, $\forall k\geqslant K$.
结合 $\|x\|_1$的凸性, 对$k\geqslant K$有

$$\|x^k\|_1+(\lambda^k)^{\mathrm{T}}Ax^k\leq\|x\|_1+(\lambda^k)^{\mathrm{T}}Ax$$

由于 $H^{k_j}=0$, 取$x^k\in U^{j_k}$且 $\|\mathrm{A}\tilde{x}-b\|=0$, 根据 x^k的最优性, 得到

$$\frac{\sigma}{2}\left\|Ax^k-b\right\|^2\leq\|\tilde{x}\|_1-\left\|x^k\right\|_1+(\lambda^k)^TA(\tilde{x}-x^k)+\frac{\sigma}{2}\|A\tilde{x}-b\|^2\leq 0.$$

因此由上式联合引理 **2** 可知, $x^k(k\geqslant K)$ 都是问题(90) 的最优解.至此, 简单基追踪问题的 ALM 收敛性定理证毕.

□ 对偶问题的增广拉格朗日函数法

考虑另一重要的问题. 设对偶问题(92): $\min_{y\in R^m,\, s\in R^n} b^{\mathrm{T}}y, \quad \text{s.t. } A^{\mathrm{T}}y - s = 0, \quad \|s\|_\infty \le 1.$

引入拉格朗日乘子 λ 和罚因子 σ, 作增广拉格朗日函数

$$L_\sigma(y,s,\lambda) = b^T y + \lambda^T (A^T y - s) + \frac{\sigma}{2}\| A^T y - s\|_2, \| s\|_\infty \le 1.$$

增广拉格朗日函数法的迭代格式为 ($\rho > 1$和$\bar{\sigma} < +\infty$)为算法参数:

$$\begin{cases} (y^{k+1}, s^{k+1}) = \arg\min\limits_{y,\| s\|_\infty \le 1} \left\{ b^T y + \frac{\sigma_k}{2}\left\| A^T y - s + \frac{\lambda}{\sigma_k}\right\|_2^2 \right\}, \\ \lambda^{k+1} = \lambda^k + \sigma_k \left(A^T y^{k+1} - s^{k+1} \right), \\ \sigma_{k+1} = \min\left\{ \rho\sigma_k, \bar{\sigma} \right\}. \end{cases}$$

其中的 (y^{k+1}, s^{k+1}) 显式表达式未知, 需要迭代求解.

口 消元法求解子问题

除了利用投影梯度法求解关于 (y, s) 的联合最小化问题外, 还可以利用最优性条件将 s 用 y 来表示, 转而求解只关于 y 的最小化问题.

关于 s 的极小化问题为

$$\min_s \frac{\sigma}{2}\left\|A^T y - s + \frac{\lambda}{\sigma}\right\|_2^2, \quad \text{s.t.} \| s\|_\infty \le 1.$$

这是一个关于 s 的二次型函数, 因此问题的解为

$$s = \mathrm{P}_{\| s\|_\infty \le 1}\left(A^T y + \frac{\lambda}{\sigma}\right),$$

其中$\mathrm{P}_{\| s\|_\infty \le 1}(z)$为集合$\{s| \ // s // _\infty \leqslant \ 1\}$ 的投影算子, 即

$$\mathrm{P}_{\| s\|_\infty \le 1}(z) = \max\{\min\{z, 1\}, -1\}.$$

.

口 消元法求解子问题

将上述s 的表达式代入的增广拉格朗日函数法的迭代格式, 得

$$\begin{cases} y^{k+1} = \arg\min\limits_{y}\left\{b^T y + \frac{\sigma}{2}\left\|\psi\left(A^T y + \frac{\lambda}{\sigma}\right)\right\|_2^2\right\}, \\ \lambda^{k+1} = \sigma_k \psi\left(A^T y^{k+1} + \frac{\lambda^k}{\sigma_k}\right), \\ \sigma_{k+1} = \min\left\{\rho\sigma_k, \bar{\sigma}\right\}. \end{cases} \tag{98}$$

其中 $\psi(x) = \text{sign}(x)\ \max\{|x| - 1,\ 0\}.$

我们不能得到关于 y^{k+1} 的显式表达式. 但是由于 $L_{\sigma k}(y,\ \lambda^k)$关于 y 连续可微, 故可以利用梯度法求解.

可

□ 对偶问题的收敛性定理

定理

假设 $\{y^k\},\{\lambda^k\}$ 是由迭代格式(98) 产生的序列, 并且 y^{k+1}的求解精度满足(87) 式的不精确条件, 而矩阵 A 是行满秩的. 那么,

(1)序列$\{y^k\}$是有界的, 且其任一聚点均为问题(92) 的最优解; (2) 序列$\{\lambda^k\}$ 有界且收敛, 其极限为原始问题 (90) 的某个最优解.

对上述 2 个定理的关系做简单的介绍. 记 $\phi_k(y)=L_\sigma(y,\lambda^k)$, 则根据凸问题的增广拉格朗日函数法, 若要保证算法收敛, 需

$$\phi_k(y^{k+1})-\inf\phi_k\le\frac{\varepsilon_k^2}{2\sigma_k},\quad \varepsilon_k\ge 0,\quad \sum_{k=1}^{\infty}\varepsilon_k<\infty,$$

其中 ε_k 是人为设定的参数.

口 一般线性规划问题的增广拉格朗日函数法

一般的线性规划问题可描述为

$$\min_x c^T x, \quad \text{s.t. } Ax = b, x \geq 0.$$

其对偶问题为

$$\max_y b^T y, \quad \text{s.t. } A^T y + s = c, s \geq 0.$$

其中$A \in \mathrm{R}^{m \times n}(m \leqslant n), x \in \mathrm{R}^n, s \in \mathrm{R}^n, y \in \mathrm{R}^m.$

首先还是先写出对偶问题的增广拉格朗日函数

$$L_{\sigma_k}(y, s, \lambda) = -b^{\mathrm{T}} y + (\lambda^k)^{\mathrm{T}}(A^{\mathrm{T}} y + s - c) + \frac{\sigma_k}{2} \| A^{\mathrm{T}} y + s - c \|_2^2, s \geq 0.$$

口 一般线性规划问题的增广拉格朗日函数法

因此根据对偶问题的增广拉格朗日函数, 设计迭代算法为

$$\begin{cases} (y^{k+1}, s^{k+1}) = \arg\min\limits_{y\in\mathbb{R}^n, s\geq 0} L_{\sigma_k}(y, s, \lambda^k) = \arg\min\limits_{y\in\mathbb{R}^n, s\geq 0} \left\{ -b^{\mathrm{T}} y + \frac{\sigma_k}{2} \left\| A^{\mathrm{T}} y + s - c + \frac{\lambda^k}{\sigma_k} \right\|_2^2 \right\} \\ \lambda^{k+1} = \lambda^k + \sigma_k \left(A^{\mathrm{T}} y^{k+1} + s^{k+1} - c \right), \\ \sigma_{k+1} = \min\left\{ \rho\sigma_k, \bar{\sigma} \right\} \end{cases}$$

并且还是用最优性条件将 s 用 y 表示(消元法), 得到上述关于 s 的二次型函数中使得 s 极小化的解为

$$s = \arg\min_{s\geq 0} \left\| A^{\mathrm{T}} y + s - c + \frac{\lambda}{\sigma} \right\|_2^2 = \mathrm{P}_{\mathbb{R}_+^n} \left(c - A^{\mathrm{T}} y - \frac{\lambda}{\sigma} \right)$$

口 一般线性规划问题的增广拉格朗日函数法

将上述s 解的表达式代入上述迭代算法, 可得约减式

$$\begin{cases} y^{k+1} = \arg\min\limits_{y\in\mathbb{R}^n, s\geq 0}\{-b^{\mathrm{T}}y + \frac{\sigma_k}{2}\left\|\psi(y,\lambda^k,\sigma_k)\right\|_2^2\}, \\ \lambda^{k+1} = \sigma_k\psi(y^{k+1},\lambda^k,\sigma_k), \\ \sigma_{k+1} = \min\left\{\rho\sigma_k, \bar{\sigma}\right\}. \end{cases}$$

其中 $$\psi(y,\lambda^k,\sigma_k) = \mathrm{P}_{\mathbb{R}^n_+}\left(A^{\mathrm{T}}y + \frac{\lambda^k}{\sigma_k} - c\right)$$

这样, 仍利用梯度法或半光滑牛顿法即可求解上述的迭代算法, 以最终解决一般线性规划问题.

感谢观看

大数据优化：理论、算法及其应用

主讲人：彭振华

数学与计算机学院

2026年